



中南大學
CENTRAL SOUTH UNIVERSITY

本科毕业论文(设计)

GRADUATION THESIS (DESIGN)

题 目	基于闭式解算法的 持续学习方法与算法实现
学 生	李家旭
学 号	8208220522
专业班级	计算机科学与技术 2204
指导教师	赵荣昌
学 院	计算机学院

本科生院制

2026 年 6 月

基于闭式解算法的持续学习方法与算法实现

摘要

持续学习需要解决问题是：当数据分批流入并且类别的集合不断变化的情况下，模型既要适应新的任务，又不能忘记之前学到的知识。当前大多数的工作都是利用梯度下降进行在线更新，容易受到梯度冲突的影响导致发生灾难性遗忘；而重放样例的方法虽然可行但是带来了很大的空间消耗以及隐私问题。本文另辟蹊径，从闭式解的角度出发，对基于解析学习的持续学习方法进行了总结归纳。

研究从整理递归岭回归闭式解开始，将其归纳为一个整体的数学表达式：在起始部分训练出编码器固定不动，只对解析分类头进行递归更新，使得增量学习可以转化为有正则化的最小二乘法的问题；同时给出了一种不需要使用之前所有原始样本的递推公式并且进行了证明，在此基础上本文在几个不同任务中进行算法实现及实验测试。其中包括：医学图像疾病分类用于说明解析持续学习学习在隐私安全的应用场景；时间序列分类结合多尺度特征融合以及随机高维映射解决灾难性遗忘和类内差异的问题；对于类别增量语义分割提出一种将随机高维映射和伪标签结合起来的持续学习分割方案，可以同时处理二维图像和三维点云；对于多模态语言模型提出一种基于解析式低秩专家选择头来完成高效的专家路由的方法。

综合全面的实验显示所提出的方法对于语义分割、医学图像分类、时间序列分类以及多模态语言模型专家路由这几种任务均能获得优秀的结果，同时大大减少持续学习期间的学习成本并且无需使用任何以往的数据进行回放。

关键词：持续学习；医学图像分类；语义分割；时间序列分类；多模态大语言模型

Continual Learning Methods and Algorithm Implementation Based on Closed-form Solution

ABSTRACT

Continual learning needs to address the following problem: when data arrive in batches and the set of categories changes continuously, a model must adapt to new tasks while avoiding forgetting previously acquired knowledge. Most existing works rely on gradient descent for online updates, which are vulnerable to gradient conflicts and may lead to catastrophic forgetting. Although replay-based methods are feasible, they introduce substantial storage overhead and privacy concerns. This paper takes an alternative route by summarizing and systematizing continual learning methods based on analytical learning from the perspective of closed-form solutions.

The study begins by organizing the closed-form solution of recursive ridge regression and generalizes it into a unified mathematical expression. In the initial stage, an encoder is trained and then kept fixed, while only the analytical classification head is recursively updated. In this way, incremental learning can be transformed into a regularized least-squares problem. Meanwhile, the paper presents and proves a recursive formula that does not require access to all previous raw samples. Based on this formulation, the proposed algorithms are implemented and experimentally evaluated across several different tasks. These include medical image disease classification, which demonstrates the application of analytical continual learning in privacy-sensitive scenarios; time-series classification, where multiscale feature fusion and random high-dimensional mapping are combined to address catastrophic forgetting and intra-class variation; class-incremental semantic segmentation, for which a continual segmentation framework integrating random high-dimensional mapping and pseudo-labeling is proposed to handle both 2D images and 3D point clouds; and multimodal language models, where an analytical low-rank expert selection head is introduced for efficient expert routing.

Comprehensive experiments show that the proposed methods achieve strong performance across semantic segmentation, medical image classification, time-series classification, and expert routing in multimodal language models. At the same time, they substantially reduce the learning cost during continual learning and require no replay of previous data.

Key words: Continual Learning; Medical Image Classification; Semantic Segmentation;
Time Series Classification; Multimodal Large Language Models

目录

第 1 章 引言	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.3 本文研究内容	4
1.4 本文的主要贡献	5
1.5 论文组织结构	5
1.6 本章小结	6
第 2 章 持续学习研究现状	7
2.1 持续学习问题与典型设定	7
2.2 基于回放的持续学习方法	9
2.3 基于正则化的持续学习方法	11
2.4 基于结构扩展或参数隔离的方法	13
2.5 基于解析持续学习的方法	14
2.6 评价指标	15
2.7 本章小结	16
第 3 章 持续学习闭式解方法	17
3.1 问题定义	17
3.2 岭回归闭式解	18
3.3 累积矩阵的分块表示	18
3.4 递归更新定理与证明	19
3.5 持续学习闭式求解算法	21
3.6 算法分析	22
3.7 本章小结	23
第 4 章 面向多场景持续学习的闭式求解算法应用	24
4.1 基于闭式求解的医学影像疾病分类	24

4.1.1	场景特点与方法适配	25
4.1.2	总体框架	25
4.2	基于闭式求解的时间序列分类	26
4.2.1	场景特点与方法适配	26
4.2.2	总体框架	27
4.2.3	集成扩展	28
4.2.4	闭式解为何适合时间序列	28
4.3	基于闭式求解的语义分割	29
4.3.1	场景特点与方法适配	29
4.3.2	总体框架	30
4.3.3	二维图像与三维点云统一建模	31
4.3.4	二维图像伪标签策略	31
4.3.5	三维点云伪标签策略	32
4.4	基于闭式求解的多模态大语言模型专家路由	33
4.4.1	场景特点与方法适配	33
4.4.2	总体框架	34
4.4.3	多模态隐藏状态特征提取	36
4.4.4	专家选择头的闭式解更新	37
4.4.5	推理过程	38
4.5	本章小结	38
第 5 章	实验结果与分析	39
5.1	医学图像疾病分类实验	39
5.1.1	数据集与设置	39
5.1.2	评价指标与对比方法	40
5.1.3	主要结果分析	40
5.1.4	结果讨论	41
5.2	时间序列分类实验	41

5.2.1	数据集与设置	41
5.2.2	评价指标与对比方法	42
5.2.3	稳定性与可塑性分析	43
5.2.4	消融实验	44
5.2.5	效率分析	45
5.3	语义分割实验	45
5.3.1	数据集与设置	45
5.3.2	评价指标与对比方法	46
5.3.3	二维图像结果分析	46
5.3.4	三维点云结果分析	49
5.3.5	消融实验	50
5.3.6	效率分析	51
5.4	多模态大语言模型专家路由实验	52
5.4.1	数据集与设置	52
5.4.2	评价指标与对比方法	52
5.4.3	主要结果分析	52
5.4.4	方法优势与讨论	54
5.5	本章小结	56
第 6 章	结论与展望	57
6.1	全文总结	57
6.1.1	统一数学框架的建立	57
6.1.2	四类典型任务的应用扩展	57
6.1.3	统一实验体系下的系统验证	58
6.1.4	方法整体优势	58
6.2	方法局限性	59
6.2.1	对初始阶段编码器的依赖	59
6.2.2	解析分类头的表达力上限	59

6.2.3	任务结构假设较强.....	59
6.3	未来研究展望.....	59
6.3.1	结合大规模预训练与基础模型.....	59
6.3.2	解析分类头模型的非线性扩展.....	60
6.3.3	面向开放世界的任务结构扩展.....	60
6.4	本章小结.....	60
	致谢.....	61

第1章 引言

持续学习旨在使模型能够在数据分布随时间发生变化的情况下不断接受新信息的同时尽可能地保持之前学到的知识^[1-5]。这与传统的静态监督学习有很大的区别，在传统的静态监督学习中可以一次性获取所有的训练样本，而在持续学习中是要面对一个一个到来的数据流、不断增加的类别数目以及资源有限的情况等。因此问题也就随之改变，不再是单纯的“如何拟合当前的数据”，而是要解决“如何在记住以前的任务的情况下还要学习新的任务”。^[1,6-7]。这个问题在医学图像分析^[8-9]、语义分割^[10-11]、时间序列感知^[12-13]以及多模态大语言模型^[14-17]等多个方面都尤为突出——即一方面需要模型具有长期学习的能力，同时在鲁棒性、有效性和隐私性等方面也有着较高的期望。

1.1 研究背景与意义

从 ResNet^[18] 到 ViT^[19]、再到当前的多模态大模型^[20-21]，深度学习在图像分类、目标识别^[22]、语义分割^[23-24]、序列建模^[12]等方向上的进展，构成了过去十几年这一领域最显眼的部分。这里有一个常常被默认、但实际上很强的前提：模型是在训练阶段可以“一次性看到全部数据”的条件下被训练出来的^[1-2]。

但是现实世界并非如此，实际上，在临床诊断中，新型疾病、新病理亚型、新成像设备等不断加入到数据库中^[8-9,25]；机器人或者自动驾驶车辆上线后，会遇到之前未见过的物体类型^[3,26-27]；传感器端时间序列任务，会不断出现新的人类活动或者新的工作情况^[12-13]；而对于多模态大语言模型来说，这更是司空见惯的情形——新的任务进入系统几乎不可避免，而且需要相应的引入新的技能模块^[14-17,28]。综合上述这些情况可以看出，无论哪种情况都指向一个共同点，即模型要在无法充分回顾过往信息的情况下，接受一个又一个的新任务。

持续学习中最棘手的问题是灾难性遗忘——它的具体表现是模型在学习新任务的过程中，参数更新破坏了旧任务上已经组成的判别边界，进而激发早期任务性能的明显下滑^[6-7,29-30]。如果暂时把数据可访问性这一约束放在一边，把各阶段数据 $\mathcal{D}_1, \dots, \mathcal{D}_t$ 同时呈现给模型，那么理想情况下的最优参数可由如下联合训练目标给出：

$$\theta_{1:t}^* = \arg \min_{\theta} \sum_{k=1}^t \mathbb{E}_{(x,y) \sim \mathcal{D}_k} [\ell(f_{\theta}(x), y)], \quad (1-1)$$

该目标在持续学习领域被视为上界参考^[1-2]。但在真实的持续场景中，阶段 t 只能观察到 $\mathcal{D}_t$ ，所以反向传播带来的更新只映射当前任务的梯度方向 $\mathbf{g}_t$ 。一旦某个历史任务的

代表梯度 g_k ($k < t$) 与之夹角超过九十度，即符合

$$g_t^\top g_k < 0, \quad (1-2)$$

当前的更新就会同时把旧任务损失变高，而这正是遗忘在几何层面上的成因^[7,14,31-32]。图 1-1 对此给出了非常直观的刻画：损失景观表明参数自历史任务最优点 θ_1^* 沿当前任务的梯度方向漂移到 θ_t 之后已经偏离了原来的低谷，所以由此引致旧任务性能下降，导致了遗忘。




图 1-1 灾难性遗忘与梯度冲突示意图。左：在损失景观中参数沿新任务梯度方向移动，致使在旧任务最优点 θ_1^* 附近的性能下滑；右：当前任务的梯度 g_t 与历史任务的梯度 g_k 夹角超过九十度，满足内积条件 $g_t^\top g_k < 0$ ，从几何层面揭示了遗忘的来源。

对于这些问题，根据不同的更新机制，已经有一些相关的工作可以分为三类传统的做法即基于回放、基于正则化以及基于结构扩展的方法^[1-4]，第一类是回放方法，它们的基本思想就是利用保存的历史样本、缓存特征或者伪样本来减少遗忘，例如 iCaRL^[26]、EEIL^[33]、ER^[34]、DER^[35]和 GEM/A-GEM^[31-32]等，这些方法在公开的数据集上效果不错，但是需要大量存储历史的信息，在医疗领域、隐私敏感的信息或者是嵌入式设备中这样的假设一般是不能满足的；第二类是正则化方法，它们希望通过限制重要的参数变化来保护之前的知识，如 EWC^[29]、SI^[30]、MAS^[36]和 LwF^[37]等，但是这种做法也有缺点，那就是参数的重要程度一般只能通过局部近似得到，而且随着任务的数量增加，正则化的惩罚会越来越难平衡稳定性和灵活性^[3]；第三类是结构扩展或者参数隔离方法^[38-40]，它们试图通过引入可动态调整网络、专家模块或是任务相关的参数降低不同任务间的干扰，但同时也面临着如何设计路径、选取何种组件等问题^[41-43]。

进一步地,大部分持续学习方法都基于梯度下降^[1-2]。新任务产生的梯度直接作用到已有的参数上,而且任务之间的梯度方向经常是不同的,这也是造成遗忘的一个原因^[7,14,31]。也就是说,在使用反向传播进行更新的情况下,旧的知识就会受到新的知识的影响。因此,从优化的角度来研究持续学习问题是有意义的。与基于梯度的方法不同,闭式解方法以解析的形式求出最优分类器参数而无需进行多次反向传播和数据回放^[44-48]。因此它们是很有潜力实现隐私保护并且高效持续学习的方法^[44-45,49-50]。

闭式解持续学习的研究意义可以从多个方面进行阐述,在理论上,它提供了一个持续学习能否不需要梯度更新的新视角去研究^[44-46],同时也是一个从理论上研究稳定性和可塑性一致性的切入点;在算法上,因为闭式解一般可以把持续更新转化为一个矩阵递推的过程,所以只需要一轮或者一次的数据前向传播就可以实现对新任务的学习从而大大降低了计算成本^[47-48,51];从应用的角度来看,该方法本身就很适合那些不能长期保存原始样本的应用场景如医学图像、用户个人隐私信息或工业物联网终端设备等;而在系统层面,由于闭式解具有较好的灵活性它可以被应用于诸如疾病的识别和时间序列分类这类较为传统的分类任务^[12,26],也可以推广到语义分割以及多模态大语言模型专家路由这样更为复杂的问题中去^[10-11,28,43]。

1.2 国内外研究现状

关于持续学习相关工作,目前已有的研究主要分为三个流派,即回放、正则化、结构扩展^[1-5]。最早被广泛关注的是分类任务^[26,29,37];随后该领域逐渐拓展到分割以及时序建模等方面^[10-13];近年来又进一步推广至多模态大语言模型方面^[14-17,28]。

近年来,解析学习以及闭式解的方法逐渐受到重视^[44-50]。它们的基本出发点并不是通过多次迭代来改进分类头,而是将特征映射后的学习问题转化为最小二乘或者岭回归的形式,然后利用矩阵求逆或者递归来获得一个最优解。这种方法最初主要是用于单次批学习中,在此基础上发展出了适应不断有新样本到来情况下的递推求解方法,在无需访问旧的原始样本的情况下也能保存下来之前的信息并且进行准确更新^[44-46,51]。本文工作也是沿着这个方向进行研究,“历史知识保留”不再是通过重播或者梯度限制的方式实现,而是转变成对于自相关矩阵以及互相关矩阵的递推维护的问题,从而使得整个过程更加简洁明了。

然而,闭式解持续学习还在快速发展之中,目前的研究大多局限于图像分类这类比较常见的任务设置^[44,46-47]。而对于更加接近实际应用场景的问题,还存在许多亟需解决的问题,如如何将闭式解的思想从分类推广到像素级或者点级别的预测,比如语义分割^[10-11];如何在类内变化较大的数据集例如时间序列上实现稳定性和可塑性并存的问题^[12-13];如何将闭式解的方法与参数分离或者专家系统结合起来应用于多模态的大语

言模型的路由问题^[28,41-43]；如何设计一种通用的数学结构使得各种不同类型的任务都可转化为一类递归解析问题进行处理。对这些问题的研究不仅可以促进闭式解持续学习的发展和完善，也可以使它更好的服务于各种不同的领域。

1.3 本文研究内容

本文围绕“基于闭式解算法的持续学习方法与算法完成”这一主题，在不同任务场景上展开成体系的研究。整体的研究思路如下：首先在数学层面构建统一的递归岭回归闭式解框架，将其作为全文方法论的核心；其次以该框架作为基础，分别面向医学图像疾病分类、时间序列分类、语义分割以及多模态大语言模型专家路由四类典型任务给出具体的应用方法；最后在统一的实验体系下对上述方法做整体验证。

本文的具体研究内容如下。

第一，本文构建了递归岭回归闭式解算法的统一数学基础。凭借冻结编码器、仅对解析分类头做持续更新，持续学习中的训练问题被转化为带正则项的最小二乘问题；在此之上，引入递归更新机制，仅借助上一阶段的统计量与当前任务的数据就能得到与联合训练一致的闭式解。这一部分构成全文方法论的核心。

第二，在医学领域中由于新出现疾病种类不断增加以及以往的数据不能保存的隐私问题，本文以疾病的分类作为应用出发点，将上述统一闭式解推广到医学影像中的分类持续学习的方法并从平均准确度、遗忘率、训练开销及数据隐私性几个方面对其优劣进行了阐述^[8-9,25]。

第三，对于时间序列上的持续学习问题，我们研究闭式解方法对于类内变化的鲁棒性，给出基于多尺度特征融合以及随机高维映射的时间序列闭式解方案^[12-13,52]，并通过集成提高其鲁棒性。

第四，对于语义分割的持续学习任务，我们使用闭式解分类头以及高维随机映射的方法，并对二维图像以及三维点云设计不同的伪标签生成方式^[10-11,23-24]从而得到一种无需样本回放的方式进行类别持续的语义分割方法。

第五，在面向多模态大语言模型的持续学习场景下，我们在专家路由问题上也应用了闭式解的思想^[20-21,28,41-43]：采用多模态大语言模型最后一层隐藏状态表示语义并用解析方式进行专家选择头学习从而实现快速并且无遗忘的专家路由。

第六，本文在统一实验体系下对上述方法做了一轮覆盖性的评估，覆盖医学图像、时间序列、二维图像与三维点云语义分割以及多模态大语言模型专家路由这四类任务，从平均准确率、遗忘率与运行效率等多个角度全面证实所提方法的有效性。

本文所做的研究并不是针对一个任务单独进行，而是以闭式解持续学习这一主线贯穿始终，由浅入深，从理论一直到视觉、时序以及多模态的任务，在一个相同的实验设

置下进行分析。

1.4 本文的主要贡献

围绕以上六个方面的工作，在此基础上总结出本文的主要创新点共有四个方面：第一个方面是全文方法论思想主线，贯穿这六方面的研究工作即用闭式解代替持续阶段反向传播的整体思路；第二个方面是与第一个方面的第一个研究内容相对应的角度，给出了一个统一的递归岭回归闭式解的框架；第三个方面是与第二个到第五个方面的研究内容相对应的角度，把这个框架推广到了医学图像、时间序列、语义分割以及多模态大语言模型专家路由这四个代表性应用领域；第四个方面是与第六个方面的工作相对应的角度，从效率、隐私和工程可行性三个方面体现出了闭式解的优势。即：

思路提炼。本文总结和归纳了梯度更新是导致持续学习中出现遗忘的主要原因^[7,31-32]，然后给出了一种用闭式解形式的方法来代替持续学习中的反向传播的思想，从而给持续学习提供一种不同于回放、正则化以及结构扩展这三种已有的方法的新思路。

统一框架。本文提供一种统一的递归岭回归闭式解框架^[44-46]，利用保存的历史统计量进行迭代更新解析分类头，并从理论上证明这种更新方法得到的结果等价于相应的联合训练结果，有利于后面各种应用场景。

多任务推广。本文将闭式解持续学习方法扩展到多种任务上，包括医学影像疾病的诊断^[8]、类持续语义分割^[10-11]、时间序列分类^[12]以及多模态大语言模型专家路由^[28,43]等，在不同方面验证了这种方法的有效性和鲁棒性。

效率及隐私优势。本文介绍了闭式解方法的优势。相比于需多次训练并进行历史数据回放的方法，本文提出的方法只需要一次遍历当前任务的数据即可完成更新工作，因此更加适合资源有限或者对数据有较高保护要求的应用场景^[47,53]。

1.5 论文组织结构

全文一共分为六章，各章节具体安排如下。

第一章是绪论部分，主要包括本课题研究目的及意义、国内外相关研究概况、本文的研究内容、创新点等以及全文的整体框架等。

第二章对持续学习相关研究进行总结，在问题定义、应用场景及方法分类的基础上概述现有工作，着重介绍基于回放、基于正则化、基于结构扩展或参数隔离以及基于解析学习这四种方法的思想、不足之处及其评价标准等，为后文具体方法做铺垫。

第三章为方法章节，在此部分主要完成递归岭回归闭式解算法的基础理论研究工作即给出问题定义、岭回归闭式解、持续递推公式及其相关证明，这是全文方法论基础部分。

第四章是应用章节，在第三章建立统一数学基础上，对医学图像疾病分类、时间序

列分类、二维图像和三维点云语义分割以及多模态大语言模型专家路由四种常见问题提出相应的闭式解持续学习解决方案。

第五章为实验结果及分析，在同一套实验环境下对第四章提出的四种不同类型的任务进行测试。本章首先介绍各个任务所用到的数据集和相关配置信息、所使用的评估标准及比较方式，然后给出主要的结果并对其原因进行讨论。

第六章为结论，总结了本论文主要研究内容并指出现有闭式解持续学习方法在未来可以在更大规模模型上、更为复杂的任务结构上以及开放世界学习中进一步应用和发展。

为了使文章层次分明，在第 1 至第 6 章后都有一节小结，对本章内容进行简单总结并且过渡到下一部分内容。

1.6 本章小结

本章首先介绍了持续学习研究的意义及其面临的挑战，在梯度反向传播造成灾难性遗忘的同时还存在隐私和存储成本问题制约了其应用；其次总结了回放、正则化、结构扩展及解析持续学习四种常见方法并提出在闭式解角度上仍有一定的改进余地；最后概述本文工作内容、四大亮点以及全文框架。接下来的第 2 章将全面介绍各种持续学习的方法并给出本文使用的评估标准。

第 2 章 持续学习研究现状

本章总结回顾持续学习相关工作。一方面需要总结持续学习基本问题以及困难所在，以便后面章节内容展开奠定基础；另一方面需要按不同方法主要思想把现有工作划分到几大类中，并对其代表工作进行分析比较优势劣势等，从而突出本文围绕闭式解研究思路。本章组织结构如下：第 2.1 节首先提出持续学习问题及常见应用场景；第 2.2 至第 2.4 节分别阐述基于回放、基于正则化以及基于结构扩展或者参数隔离三种传统方法；第 2.5 节着重介绍了本文所采用的解析持续学习方法；第 2.6 节简单介绍了持续学习领域常用评估标准；第 2.7 节为本章总结。本章所使用的图片及分类依据主要参考最近关于持续学习综述性文章^[1-4]。

如图 2-1 所示，持续学习也可视为一种动态环境中的机器学习问题，在长时间运行中不仅要拟合当前的数据分布还要能够在数据分布以及任务目标甚至是模型本身发生变化时仍具有良好的鲁棒性^[4]。




图 2-1 动态场景下的机器学习问题示意。在长期部署期间，模型不仅要应对数据分布的变化，还可能要同步应对任务、模型与目标的变化（图源 王仁振 等^[4]）。

2.1 持续学习问题与典型设定

持续学习，在相关文献中也被称作增量学习或者终身学习。它所关心的一个问题可以表述为：如果数据以批次的形式不断流入，类别集合或者数据分布发生变化的情况下，如何让模型保持对早期任务的识别能力的同时获得新任务的知识^[1-2]。而这个最大的挑战就是稳定性——可塑性困境，即一个过于稳定的学习器无法学到新的任务，而一个过于灵活的学习器又会把之前学到的知识忘掉^[6-7]。

把这一困境再做一层形式化的刻画会更直观。记阶段 t 上的损失为 $\mathcal{L}_t(\theta)$ 、全阶段联合训练损失为 $\mathcal{L}_{1:T}(\theta) = \sum_{k=1}^T \mathcal{L}_k(\theta)$ ，则持续学习的隐含目标是让顺序训练得到的参数 θ_T 尽可能接近 $\arg \min_{\theta} \mathcal{L}_{1:T}(\theta)$ 。然而在阶段 t 上若仅最小化 $\mathcal{L}_t$ ，其梯度 $\nabla \mathcal{L}_t$ 一旦与某个 $\nabla \mathcal{L}_k (k < t)$ 方向不一致，顺序更新就会拉着参数沿对历史任务而言上坡的方向移动，表征空间随之发生漂移、旧类别的判别边界由此被破坏^[1,3]。而从表示学习的角度来看，则是新旧类别的表示之间重叠程度增加以及分类器的权重改变，这也正是下面将介绍的解析持续学习方法选择一次求出所有阶段的最佳分类器的原因所在：而不是每一步都进行小范围梯度下降并且希望正则化项可以纠正方向，而是直接消除局部最优解与全局最优解之间的差异。

参考综述^[1-3]的分类，当前常见的持续学习场景大致可划入图 2-2 所呈现的三种典型设定。




图 2-2 三种典型增量学习设定示意：任务增量学习（Task-IL）、类别增量学习（Class-IL）与域增量学习（Domain-IL）（图源 周大蔚 等^[3]）。

最宽松的是任务增量学习 (Task-Incremental Learning, Task-IL)：每一轮是一个具体任务 (例如不同分类问题或者不同输出空间)，并且在推理时也知道当前样本来自什么任务，在这个任务对应的输出空间中进行判断即可。限制最少，一般作为算法测试的基础环境。

然后难度提升一个等级是类别增量学习 (Class-Incremental Learning, Class-IL)。每一个新阶段都会有新的类别出现，但是这些新的类别不会与之前出现过的类别有交集；在测试过程中需要让模型对所有的类进行一次分类并且在推理过程中不再告知模型当前

的数据属于哪一个任务^[3]。这也是目前研究最多的一个场景，本文所关注的医学图像疾病的分类、时间序列分类、语义分割以及多模态模型专家路由的问题中都属于此类。Class-IL 训练-测试的过程如图所示。Class-IL 的训练-测试协议示意图 2-3。




图 2-3 类别增量学习问题设定示意：模型按顺序学习不断到来的新类别，并在所有已见过的类别上接受测试（图源 周大蔚 等^[3]）。

第三类是域增量学习（Domain-Incremental Learning, Domain-IL）。它的特点恰好与 Class-IL 互补：类别集合大体固定，但输入分布会在不同阶段发生变化——可能是不同环境、不同采集设备、或者不同领域。

除了以上三种主要设置外，在一些工作中也存在一些变种：在线持续学习（online continual learning）对每一个样本仅进行一次遍历^[53]；少样本持续学习（few-shot CL）针对新任务中较少的样本数量；而开放世界持续学习更进一步包括未见过的新类别识别的问题。本文主要基于 Class-IL 设置来进行讨论，因此在后续的方法部分会使用相应的符号表示。

本文统一运用以下符号约定：第 t 个阶段的数据集记为 $D_t = \{\mathbf{X}_t, \mathbf{Y}_t\}$ ，新类别集合记为 S_t 。三种设定可分别对应到：(1) Class-IL, $S_i \cap S_j = \emptyset$ 且在推理时的任务标签是未知的；(2) Domain-IL, 类别空间固定而输入数据的概率分布会变化；(3) Task-IL, 类别空间可不相交但推理阶段时任务标签已知。后续第 3 章会沿用上述记号构建统一的闭式解框架。

2.2 基于回放的持续学习方法

这是比较早的一类方法，在工业界也最受欢迎。思路非常简单：将过去的数据存储起来，在有新的任务时，让它们与新的数据一起进行学习，从而保证原有的类别的区分度^[1-2,4]。综述^[4]将回放的对象进行了分类（如图 2-4：样本回放、特征回放、生成回放。

从数学的角度看，回放方法就是把原来的单任务的目标进行一次扩大，即让历史样




图 2-4 数据层面的持续学习方法示意，涵盖样本回放、特征回放与生成回放三种典型形式（图源 王仁振 等^[4]）。

本也参与到梯度中去计算。设第 t 个阶段的缓存集是 $B_{t-1} = \{(x_b, y_b)\} \subset \bigcup_{k < t} D_k$ ，权衡系数为 $\beta > 0$ ，那么一种常见的回放方法的学习目标可以表示为

$$\min_{\theta} \frac{1}{|D_t|} \sum_{(x,y) \in D_t} \ell(f_{\theta}(x), y) + \beta \cdot \frac{1}{|B_{t-1}|} \sum_{(x_b, y_b) \in B_{t-1}} \ell(f_{\theta}(x_b), y_b), \quad (2-1)$$

其中第一部分关注对新数据拟合（可塑性），第二部分通过使模型不能远离已有训练样本（稳定性）。一种比较有代表性的方法是 iCaRL^[26]，该方法使用示例选择保留一定数量的数据集，在此基础上采用最近类均值进行预测。

$$\hat{y} = \arg \min_c \|\phi(x) - \mu_c\|_2, \quad \mu_c = \frac{1}{|B_c|} \sum_{x \in B_c} \phi(x), \quad (2-2)$$

其中 $\phi(\cdot)$ 是冻结特征提取器，而 μ_c 是缓冲区里类别 c 特征均值。这个方法至今仍是 Class-IL 的一种优秀基线。在此之上，EEIL^[33]提出了端到端的学习以及均衡微调；GEM 与 A-GEM 系列^[32]更是进了一步，使用以前的数据进行梯度合法性的检查——即新任务梯度 g_t 应该与所有历史代表性梯度 g_k 保持正值内积。

$$g_t^T g_k \geq 0, \quad k = 1, 2, \dots, t-1, \quad (2-3)$$

否则将其投影到约束空间内，从而以显式的方式防止历史损失增大。

如何维护缓冲区，这也是此类方法无法回避的问题。根据梯度信息选取样本的方法^[34,54-55]都是在样本到达的时候就判断其能否进入缓冲区以避免简单的先入先出造成

样本代表性不足的问题；MIR^[54]的做法是在每次训练中选择最难被新学到的内容所覆盖的老样本进行重放。而在回放的对象方面也有多种变种：DER^[35]将回放样本定义为样本 + 其对应的 logits，以此来保留旧模型中的判别能力；FastICARL^[56]及其相关工作都是在 iCaRL 的基础上进行轻量化部署；此外还有一些直接舍弃原始图像而只保存特征或者类原型的工作——这进一步降低存储开销和对隐私的要求。PASS++^[57]以及基于原型对齐的一系列方法^[58-59]都可以归结为这种方法。

回放方法的优点是简单易懂并且效果可靠。但是也有缺点——需要存储历史信息。而在医学影像、用户隐私数据以及边缘端部署等情况下，这往往是不能容忍的；如果缓存空间有限，则会产生样本代表性差的问题，进而导致训练集不平衡从而容易造成遗忘^[1,3]。而生成式回放则是希望通过一个生成器去拟合历史数据分布以避免这个问题。但是生成器自身也存在遗忘问题，而且对于高分辨率自然图像或者多模态的数据建模效果较差。

2.3 基于正则化的持续学习方法

正则化路径和回放路径的不同之处在于：它并不存储原始样本，在损失函数中增加一个额外的项以使重要的参数在新任务中的可移动距离受到约束。如果从优化的角度来看，这种方法实际上就是使得新旧任务损失之间梯度对齐以及损失曲面光滑^[4]如图2-5所示。

EWC^[29]、SI^[30] 和 MAS^[36] 是这一方向有影响力的工作，它们都计算每个参数的一个重要性，然后通过二次项约束使这些参数靠近之前的最优值。比如对于 EWC，在上一个任务训练结束时获得的参数是 θ^* ，其对应的重要性向量是 $\Omega = \{\omega_i\}$ ，那么在第 t 个任务中要优化的目标就是

$$\tilde{\mathcal{L}}_t(\theta) = \mathcal{L}_t(\theta) + \frac{\lambda}{2} \sum_i \omega_i (\theta_i - \theta_i^*)^2, \quad (2-4)$$

其中 $\omega_i = \mathbb{E}_{(x,y) \sim D_{t-1}} [(\partial \log p_\theta(y|x) / \partial \theta_i)^2] |_{\theta=\theta^*}$ 是费舍尔信息矩阵的对角线元素，表示参数 θ_i 在之前的任务中所起的作用；而 $\lambda > 0$ 是控制正则化项整体强度的超参数； ω_i 越大说明参数 θ_i 在以前的任务中起到的作用越大，应尽量保留它。这种方法不需要保存任何先前的数据，在隐私受到限制的情况下具有优势。

另一类正则化方法是从函数本身进行限制，最典型的的就是基于知识蒸馏的方法 LwF^[37]：在学习新任务的同时让旧模型对于当前数据的预测结果成为新模型的目标，从而使得新模型也具有类似旧任务的判别能力。它可以表示为

$$\mathcal{L}_{\text{LwF}}(\theta) = \underbrace{\mathcal{L}_{\text{CE}}(f_\theta(x), y)}_{\text{新任务交叉熵}} + \eta \cdot \underbrace{\mathcal{L}_{\text{KD}}(\sigma_\tau(f_{\theta^*}(x)), \sigma_\tau(f_\theta(x)))}_{\text{旧模型软目标蒸馏}}, \quad (2-5)$$

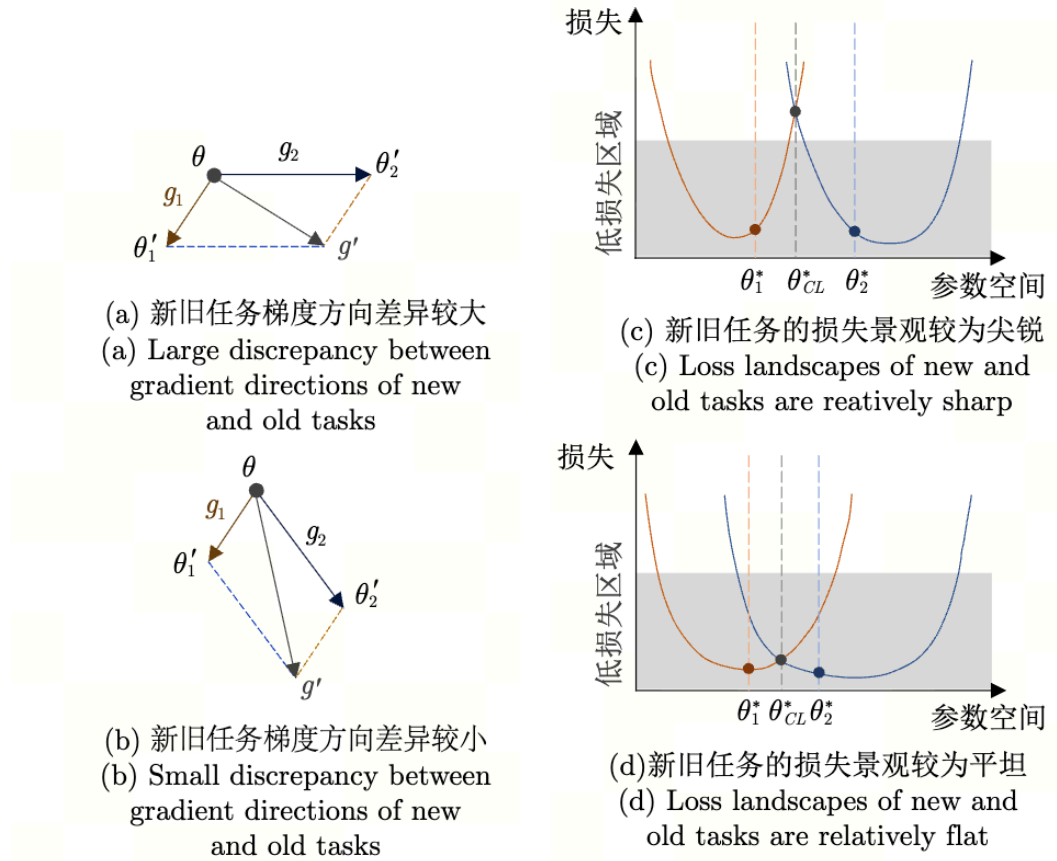


图 2-5 从优化角度考虑的持续学习策略：利用梯度对齐以及损失曲面平滑减少新旧任务之间的影响（图源 王仁振 等^[4]）。

其中 $\sigma_{\tau}(\cdot)$ 是带有温度 τ 的 softmax, f_{θ^*} 是被冻结的旧模型, η 控制蒸馏损失的比例。一般而言蒸馏损失 $\mathcal{L}_{KD}$ 使用带温度的 KL 散度或者交叉熵表示。一些后续的工作在分类及分割上对蒸馏目标进行了优化；而在语义分割中, MiB^[10]以及 PLOP^[11]提出了将背景类别建模以及中间层特征蒸馏作为重要限制条件。

在上述基本形式基础上, 后续工作沿着两个方向进行探索：一个是如何让参数重要性评估更加鲁棒：文献^[60] 使用滑动平均保存一个全局费舍尔信息, 避免为每一个任务保存一个 Ω 所带来的存储开销问题；RWalk^[61] 将 EWC 和 SI 两种重要性测度进行加权组合, 使得惩罚项对于不同类型的变化更为鲁棒。另一个是从梯度的角度来进行限制, 也就是梯度投影族的方法：首先估计已经学习的任务所对应的特征或者梯度子空间, 然后将新的任务梯度投影到这个子空间的补空间中去, 这样可以使得参数更新从理论上来说极少影响旧任务的结果^[31-32,42]。这与本文所使用的方法在思路是一致的：二者都在线性代数上给出了不破坏旧解的硬约束。但是区别也很明显：本文给出了闭式解一劳永逸, 而梯度投影族还需要不断优化并不断逼近已经学习的任务子空间, 在大量的任务之后很容易达到子空间满秩的情况。

正则化方法存在两个问题比较明显。首先，参数重要性估计是近似，当任务间差别增大时该近似便不再成立。其次，约束项大小很难在稳定性和灵活性之间取舍，在任务很多的情况下正则项往往过大以至于模型无法学习新任务^[3]。而本文的方法虽然开始时也冻结编码器，但是在后续增加过程中就不需要使用梯度来更新以及相应的正则约束，而是给出一个最优的分类头，因此从本质上避免这类方法所面临的问题。

2.4 基于结构扩展或参数隔离的方法

第三种方法不同于上面两种方法之处在于，既不对数据进行存储，也不在损失中增加约束条件，而是给每一个任务分配一个属于自己的参数子空间，使得任务之间不会发生冲突，在从结构上来划分的话，这几种方式都可以归纳为三种类型：子网络的选择、动态网络的生长、参数分离^[4]如图2-6所示。




图 2-6 在模型结构上实现持续学习的方法是利用参数隔离、子网络掩码甚至根据不同任务分配不同参数子空间等（参考文献 王仁振 等^[4]）。

Progressive Networks^[38] 是这方面最早提出的方法。它也很简单明了：每次加入一个新的任务便增加一组新的网络模块并且通过侧向连接重用之前的学习表示。Expert Gate^[39]在此基础上引入门控机制根据给定输入选择合适的专家网络。这可以避免由于参数共享导致的知识被覆盖的问题但是也带来了明显的缺点即随着任务数量增加而增加的大量的模型参数以及需要知道当前的任务是什么以便确定所使用的子结构。

走另一条路的工作是不再为每个任务创建新的结构，而是在一个公共的基础结构之上通过二值掩码或者剪枝定义出不同的任务各自的参数子集。Piggyback^[62] 让所有的任务共享一个权重矩阵，每个任务有其独立的学习得到掩码，在几乎不增加参数的情况下达到类似硬分离的效果；而 HAT^[63] 使用可学习的注意力门控代替掩码完成同样的工作。这种方法在参数效率上优于按列增加的方式，但是掩码或门控仍然需要进行梯度优化，在测试阶段也需要用到任务身份选择合适的掩码。

时间再往后一些，在大模型以及参数高效微调出现之后，基于 LoRA 等低秩适配

器的参数隔离是目前最常用的方法^[4,41-43]。即原始权重 $W_0 \in \mathbb{R}^{m \times n}$ 固定不变，每个任务的参数变化 ΔW 放在一小部分低维子空间内，然后用大小为 $U \in \mathbb{R}^{m \times r}$ 和 $V \in \mathbb{R}^{r \times n}$ ($r \ll \min(m, n)$) 两个小矩阵相乘获得。

$$W^{(t)} = W_0 + \Delta W^{(t)}, \quad \Delta W^{(t)} = U^{(t)}V^{(t)}, \quad (2-6)$$

训练过程中仅使 $\{U^{(t)}, V^{(t)}\}$ 参与梯度计算。每个任务拥有一个独立的低秩矩阵后，在新的任务中其权重更新只局限于该任务对应的子空间中，因此增加的额外参数很少，而且每个任务所独有的知识也被保留下来。而在第四章提出的多模态大语言模型专家路由方法就是基于这种专家隔离的思想——对于每一个特定的任务都有一个 LoRA 专家，而主体部分始终处于冻结状态，不同专家之间不会共享参数。

伴随大模型时代的另一条线是基于提示的持续学习，L2P^[64] 和 DualPrompt^[40] 冻结视觉或者语言骨干网络，只学习一小部分与任务相关提示向量，在推理过程中通过提示查询从这些提示中挑选出最适合当前输入的一个或者多个；CODA-Prompt^[65] 将提示组合成可微分的注意力加权形式解决了提示之间的可微性问题；Progressive Prompts^[66] 在序列任务中让提示一层一层叠加，促进积极迁移。它们的基本思路都是“固定骨干+轻量级任务部分”，即骨干不参与梯度更新，而任务知识存在于可以更换的小块里面。但是提示类方法中的轻量级任务部分仍然是需要用梯度进行优化，在较长序列的任务中容易出现不同 prompt 之间的互相影响以及提示查询头遗忘的问题。

需说明的是，参数隔离并不能完全摆脱遗忘，也需要一个路由器或者门控网络来选择在推理过程中使用哪个专家、哪些子结构。而如果这个路由器本身还要进行梯度下降训练，则它又会遗忘。我们提出的方法就是将解析学习的思想引入到路由器的学习当中，在路由器的学习中也采用闭式解的形式解决这个问题。

2.5 基于解析持续学习的方法

第四条线，也是本文方法所归属的方向，是近年来逐渐被重视解析学习持续方法。这类方法的核心思想可简化为一句话：将分类头学习从梯度迭代转变为具有正则项的最小二乘问题，然后用矩阵求逆或者递归得到全局最优解^[44-45]。已有研究表明，在标准类别增量分类任务中，只需要保留很少几个统计数据（自相关矩阵以及互相关矩阵），就可以实现增量更新，不需要存储任何历史原始数据，每轮次更新的结果都可以和对应的联合训练解析解完全一致^[46-47]。

放在前面三种途径下进行对比分析可以更加清晰地看到解析持续方法的优势所在。相比于正则化无样本方法，解析方法不需要通过惩罚项来约束参数，而是直接从理论上保证旧类别分类边界的完整性；相比于回放方法，只需要存储统计量矩阵而不是全部样

本，因此更适用于对隐私要求较高的情况。上述特点就是我们进行本课题研究的基础，在第三章中将以递归岭回归闭式解为基础建立相应的理论框架；而在第四章中将进一步将该思想应用于具体的医学图像、时间序列、语义分割以及多模态大语言模型等实际问题当中。

2.6 评价指标

为了能够在下一章节能够统一标准进行比较，在此对持续学习中常见的一些评估标准进行总结。本文所采用的标准主要参考综述^[1-3]中的三种，即平均准确率、平均遗忘率以及反向迁移。设整个任务序列有 T 个任务， $a_{t,i}$ 是模型在进行完第 t 轮学习后，在任务 i ($i \leq t$) 的测试集上所达到的效果（准确率或者 mIoU），那么这三者就可以用以下方式表示：

平均准确率 在最后一步 T 结束时，对所有以前见过的任务进行评估求平均数，即映射模型在完成所有任务后整体上所达到的准确度。

$$\text{ACC} = \frac{1}{T} \sum_{i=1}^T a_{T,i}. \quad (2-7)$$

而对于稠密预测任务，只需要将 $a_{t,i}$ 替换为相应任务上平均交并比（mIoU）。

平均遗忘率 用来衡量学习一个新任务后旧任务的性能降低的程度，在每一个旧任务 i ($i < T$) 上，把其被首次学习之后、最终阶段之前的最佳表现值用 $\max_{i \leq k \leq T-1} a_{k,i}$ 表示，则平均遗忘率为

$$\text{Forgetting} = \frac{1}{T-1} \sum_{i=1}^{T-1} \left(\max_{i \leq k \leq T-1} a_{k,i} - a_{T,i} \right). \quad (2-8)$$

其中下标取值范围是 $i \leq k \leq T-1$ 是为了保证计算历史上的最大值时仅在任务 i 已经被学习但未到最终评价的那个时间段内计算；最后的任务 T 由于不存在后续的时间段因此不在遗忘率中考虑。这个指标数值越小说明模型对于老的任务的记忆能力越强。

后向迁移 是用来评估后期的任务训练对前面的任务所起到的作用，在这里它是这样计算的

$$\text{BWT} = \frac{1}{T-1} \sum_{i=1}^{T-1} (a_{T,i} - a_{i,i}). \quad (2-9)$$

当 $\text{BWT} \approx 0$ ，说明新任务学习对原有任务辨别能力影响不大；而 $\text{BWT} > 0$ ，表示新任务学习使原有任务性能得到提升，这更好。

多模态大语言模型持续学习专用指标 在多模态大语言模型专家路由场景下，已有多领域的基线^[28]除了上述指标外还引入了以下三种评价标准：末轮全任务平均准确率 (Mean Final Total accuracy, MFT)、末轮新任务平均准确率 (Mean Final performance on Novel tasks, MFN) 以及平均累积准确率 (Mean Average Accuracy, MAA)，它们形式化的表示为

$$\text{MFT} = \frac{1}{T} \sum_{i=1}^T a_{T,i}, \text{MFN} = \frac{1}{T} \sum_{i=1}^T a_{i,i}, \text{MAA} = \frac{1}{T} \sum_{t=1}^T \frac{1}{t} \sum_{i=1}^t a_{t,i}. \quad (2-10)$$

其中 $\text{MFT} = \frac{1}{T} \sum_i a_{T,i}$ 在数学上等于公式 (2-7) 中的平均准确率 ACC，为了便于与此前相关工作保持一致，我们采用了 MLLM-CL 基准^[28]中对于此指标的称呼即最终整体识别率，用于体现整个过程最后的结果；而 $\text{MFN} = \frac{1}{T} \sum_i a_{i,i}$ 是每个任务第一次训练完成后在自身任务上的正确率，反映了模型在每一个新任务出现时立即具备的能力或者说灵活性；最后 MAA 是对所有阶段的学习过程中的平均表现再求均值，表示长久以来的效果。这三个以及 BWT 构成了第五章对于多模态大语言模型专家路由方法进行评价的标准。

第五章实验中采用以上标准评价本研究所提出的方法与其他几种基线方法。

2.7 本章小结

本章总结目前持续学习的方法体系。在问题设置上总结任务、类别以及域这三种常见情况，在此之中本文的研究集中在类别以及域这两种情况下。而从方法上看按其核心思想分为基于回放、基于正则化、基于结构扩展、三大类，分别介绍了它们各自代表的工作及其缺点；再通过示意图的形式从数据、优化、结构三个方面进行总结，参考最近的一篇综述文章^[4]的内容。然后引入近年来兴起的一种新的解析持续学习的方法，这就是本文所采用的方法的思想来源。最后简单列举一些在持续学习中常用到的评估标准以便之后实验部分能够做到公平合理。下一节将会以解析学习为基础搭建全文统一递归岭回归闭式解的基础知识。

第3章 持续学习闭式解方法

为解决持续学习在按阶段吸收新任务时由反向传播主导的参数更新所引发的灾难性遗忘问题，以及随之而来的稳定性—可塑性矛盾在传统梯度框架下难以兼顾这一核心难题，本章给出统一的理论分析，并提出基于递归岭回归的闭式求解方法。其核心思路是把持续学习增量阶段的参数更新即依赖反向传播的迭代调优问题重新表述为带正则项的递归岭回归解析求解问题，并据此推出递归更新公式，使模型仅借助上一阶段的统计量与当前阶段的样本就能完成更新。本章先界定持续学习问题的统一记号；接着从单批次岭回归闭式解出发，逐步推出递归形式；继而以严格的证明表明递归更新结果与联合训练解析解完全一致；最后从复杂度、隐私性以及可推广性这三个角度分析算法性质。本章构成第四章面向四类典型任务的应用方法的统一理论支撑。

3.1 问题定义

设持续学习过程总共包含 T 个阶段，第 t 个阶段的训练数据记为

$$\mathcal{D}_t = \{\mathbf{X}_t, \mathbf{Y}_t\}, \quad t = 1, 2, \dots, T, \quad (3-1)$$

其中 $\mathbf{X}_t \in \mathbb{R}^{N_t \times d}$ 是第 t 阶段用于解析学习的数据矩阵， N_t 为该阶段的样本数目， d 为特征维度； $\mathbf{Y}_t$ 则为相应的真值矩阵。出于统一全文记号，后续各章均以 $\mathbf{X}$ 表示数据、以 $\mathbf{Y}$ 表示真值。在类别增量学习问题中，第 t 阶段会引入新类别集合 $\mathcal{S}_t$ ，并要求不同阶段所引入的新类别互不重叠，即

$$\mathcal{S}_i \cap \mathcal{S}_j = \emptyset, \quad i \neq j. \quad (3-2)$$

持续学习场景里，模型在第 t 阶段结束之后必须同时识别截至当前已经见过的全部类别。把累计标签空间维度记为 d_{C_t} ，那么所要学习的目标就是分类头参数矩阵

$$\Phi_t \in \mathbb{R}^{d \times d_{C_t}}, \quad (3-3)$$

要求其能借助当前阶段与历史阶段累积起来的判别信息对所有已见类别做统一预测。不同任务场景下，输入张量的形态、监督形式以及类别空间大小都会存有一些差异，但增量更新这一核心问题始终可归结为对上述参数矩阵的递推求解。这里 Φ_t 是待求解的分类头变量，在岭回归意义下的最优闭式解记为 $\hat{\Phi}_t$ 。

3.2 岭回归闭式解

先来看单次批学习的情况。给定某一阶段的数据矩阵 $\mathbf{X}$ 与真值矩阵 $\mathbf{Y}$ ，解析分类头能够借助岭回归求出，对应的优化问题为：

$$\min_{\Phi} \|\mathbf{Y} - \mathbf{X}\Phi\|_F^2 + \gamma \|\Phi\|_F^2, \quad (3-4)$$

其中 $\gamma > 0$ 是正则化系数， $\|\cdot\|_F$ 代表 Frobenius 范数。

式 (3-4) 是一个标准的带 ℓ_2 正则项的最小二乘问题，它的解析解为

$$\hat{\Phi} = (\mathbf{X}^\top \mathbf{X} + \gamma \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{Y}, \quad (3-5)$$

式中 $\mathbf{I}$ 表示单位矩阵。由式 (3-5) 的单批岭回归形式可观察到，只要编码器特征已经固定，分类头的最优解就能够直接由矩阵运算得到，不需要多轮梯度迭代反向传播。

把第 1 至第 t 阶段的样本全部联合起来，对应的累计数据矩阵和累计标签矩阵则分别写作

$$\mathbf{X}_{1:t} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \\ \vdots \\ \mathbf{X}_t \end{bmatrix}, \quad \mathbf{Y}_{1:t} = \begin{bmatrix} \mathbf{Y}_1 \\ \mathbf{Y}_2 \\ \vdots \\ \mathbf{Y}_t \end{bmatrix}. \quad (3-6)$$

由于类别集合会随阶段推进不断扩张，为了让矩阵维度保持一致，历史标签矩阵在拼接时需要对尚未浮现的类别位置补零。这样，第 t 阶段对应的联合训练最优解就可写作

$$\hat{\Phi}_t = (\mathbf{X}_{1:t}^\top \mathbf{X}_{1:t} + \gamma \mathbf{I})^{-1} \mathbf{X}_{1:t}^\top \mathbf{Y}_{1:t}. \quad (3-7)$$

式 (3-7) 在理论上给出了一个理想的联合训练结果，但若直接按式计算就必须用到所有的历史样本，下面要做的就是把它改写成递归形式。

3.3 累积矩阵的分块表示

出于推导出增量更新公式，先把上一阶段的逆自相关矩阵定义为

$$\Psi_{t-1} = (\mathbf{X}_{1:t-1}^\top \mathbf{X}_{1:t-1} + \gamma \mathbf{I})^{-1}. \quad (3-8)$$

矩阵 Ψ_{t-1} 以压缩的形式保留了截至第 $t-1$ 阶段全部样本的二阶统计量，它是后续递归更新中的关键。旨在使递推过程在数值上始终良好定义，本文统一约定 $\gamma > 0$ ，并把 $\Psi_0 = (\gamma \mathbf{I})^{-1}$ 作为递推的起点；这一约定确保任意阶段的 Ψ_t 均为正定矩阵，由此 $\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top$ 始终可逆。

另一方面，第 t 阶段的当前标签矩阵能够按“旧类别部分”与“新类别部分”做拆分：

$$\mathbf{Y}_t = \begin{bmatrix} \tilde{\mathbf{Y}}_t & \tilde{\mathbf{Y}}_t \end{bmatrix}, \quad (3-9)$$

其中 $\bar{\mathbf{Y}}_t \in \mathbb{R}^{N_t \times d_{C_{t-1}}}$ 对应旧类别位置, $\tilde{\mathbf{Y}}_t \in \mathbb{R}^{N_t \times (d_{C_t} - d_{C_{t-1}})}$ 对应新类别位置。对标准的类别增量分类问题而言, $\bar{\mathbf{Y}}_t$ 一般是零矩阵; 而对于带伪标签的语义分割等问题, $\bar{\mathbf{Y}}_t$ 可包含旧类别信息。所以, 式 (3-9) 比仅应对纯新类别标签的形式要更为通用。

依照分块结构, 第 t 阶段累计标签矩阵能够表达为

$$\mathbf{Y}_{1:t} = \begin{bmatrix} \mathbf{Y}_{1:t-1} & \mathbf{0} \\ \bar{\mathbf{Y}}_t & \tilde{\mathbf{Y}}_t \end{bmatrix}, \quad (3-10)$$

累计数据矩阵则有

$$\mathbf{X}_{1:t} = \begin{bmatrix} \mathbf{X}_{1:t-1} \\ \mathbf{X}_t \end{bmatrix}. \quad (3-11)$$

把式 (3-10) 与式 (3-11) 同时代入式 (3-7), 就能得到第 t 阶段联合训练的解析解。下一节将给出其递归表达。

3.4 递归更新定理与证明

为方便后续表述, 先把本章的核心结论列出。

定理 3.1 (递归岭回归闭式解) 设第 $t-1$ 阶段的解析分类头为 $\hat{\boldsymbol{\phi}}_{t-1}$, 其逆自相关矩阵为 $\boldsymbol{\Psi}_{t-1}$ 。那么第 t 阶段的逆自相关矩阵可以按下式递归更新

$$\boldsymbol{\Psi}_t = (\boldsymbol{\Psi}_{t-1}^{-1} + \mathbf{X}_t^\top \mathbf{X}_t)^{-1}. \quad (3-12)$$

进一步地, 第 t 阶段的分类头闭式解可以表示为

$$\hat{\boldsymbol{\phi}}_t = \begin{bmatrix} \hat{\boldsymbol{\phi}}_{t-1} - \boldsymbol{\Psi}_t \mathbf{X}_t^\top \mathbf{X}_t \hat{\boldsymbol{\phi}}_{t-1} + \boldsymbol{\Psi}_t \mathbf{X}_t^\top \bar{\mathbf{Y}}_t & \boldsymbol{\Psi}_t \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \end{bmatrix}. \quad (3-13)$$

式 (3-13) 与直接使用全部历史数据所得到的联合训练解完全等价。

证明 证明的整体思路是: 第一步借助分块矩阵乘法直接给出 $\boldsymbol{\Psi}_t$ 与 $\mathbf{Q}_t$ 的二项加法分解; 第二步则借助 Woodbury 恒等式, 把 $\boldsymbol{\Psi}_t \mathbf{Q}_{t-1}$ 拆分成只依赖上一阶段统计量 $(\boldsymbol{\Psi}_{t-1}, \hat{\boldsymbol{\phi}}_{t-1})$ 与当前数据 $(\mathbf{X}_t, \mathbf{Y}_t)$ 的形式。

由式 (3-7) 可知, 第 $t-1$ 阶段的联合训练解为

$$\hat{\boldsymbol{\phi}}_{t-1} = (\mathbf{X}_{1:t-1}^\top \mathbf{X}_{1:t-1} + \gamma \mathbf{I})^{-1} \mathbf{X}_{1:t-1}^\top \mathbf{Y}_{1:t-1}. \quad (3-14)$$

为简化记号, 再把第 $t-1$ 阶段的互相关矩阵定义为

$$\mathbf{Q}_{t-1} = \mathbf{X}_{1:t-1}^\top \mathbf{Y}_{1:t-1}. \quad (3-15)$$

由此可得

$$\hat{\Phi}_{t-1} = \Psi_{t-1} \mathbf{Q}_{t-1}. \quad (3-16)$$

同理地，第 t 阶段的联合训练解可以写为

$$\hat{\Phi}_t = \Psi_t \mathbf{Q}_t, \quad (3-17)$$

而由式 (3-11) 做分块乘法展开就有

$$\mathbf{X}_{1:t}^\top \mathbf{X}_{1:t} = \mathbf{X}_{1:t-1}^\top \mathbf{X}_{1:t-1} + \mathbf{X}_t^\top \mathbf{X}_t, \quad (3-18)$$

结合式 (3-18) 的分块乘法与逆自相关矩阵的定义式 (3-8) 可得 $\Psi_t^{-1} = \mathbf{X}_{1:t}^\top \mathbf{X}_{1:t} + \gamma \mathbf{I} = \mathbf{X}_{1:t-1}^\top \mathbf{X}_{1:t-1} + \gamma \mathbf{I} + \mathbf{X}_t^\top \mathbf{X}_t = \Psi_{t-1}^{-1} + \mathbf{X}_t^\top \mathbf{X}_t$ ，再对两端取逆便得到

$$\Psi_t = (\mathbf{X}_{1:t}^\top \mathbf{X}_{1:t} + \gamma \mathbf{I})^{-1} = (\Psi_{t-1}^{-1} + \mathbf{X}_t^\top \mathbf{X}_t)^{-1}, \quad (3-19)$$

这便证明了式 (3-12)。

为了得到 Ψ_t 的显式递归形式，再对上式套用 Woodbury 矩阵恒等式

$$(\mathbf{A} + \mathbf{UCV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{U} (\mathbf{C}^{-1} + \mathbf{VA}^{-1} \mathbf{U})^{-1} \mathbf{VA}^{-1}. \quad (3-20)$$

具体地，应用式 (3-20) 的 Woodbury 恒等式，并令 $\mathbf{A} = \Psi_{t-1}^{-1}$ 、 $\mathbf{U} = \mathbf{X}_t^\top$ 、 $\mathbf{C} = \mathbf{I}$ 、 $\mathbf{V} = \mathbf{X}_t$ ，便能得到

$$\Psi_t = \Psi_{t-1} - \Psi_{t-1} \mathbf{X}_t^\top (\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top)^{-1} \mathbf{X}_t \Psi_{t-1}. \quad (3-21)$$

下面再来推导分类头的递归形式。根据式 (3-10)，第 t 阶段的互相关矩阵为

$$\mathbf{Q}_t = \begin{bmatrix} \mathbf{X}_{1:t-1}^\top \mathbf{Y}_{1:t-1} + \mathbf{X}_t^\top \bar{\mathbf{Y}}_t & \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \end{bmatrix}. \quad (3-22)$$

借助式 (3-15) 就可以把它改写成

$$\mathbf{Q}_t = \begin{bmatrix} \mathbf{Q}_{t-1} + \mathbf{X}_t^\top \bar{\mathbf{Y}}_t & \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \end{bmatrix}. \quad (3-23)$$

把式 (3-23) 代入式 (3-17)，便有

$$\hat{\Phi}_t = \begin{bmatrix} \Psi_t \mathbf{Q}_{t-1} + \Psi_t \mathbf{X}_t^\top \bar{\mathbf{Y}}_t & \Psi_t \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \end{bmatrix}. \quad (3-24)$$

所以接下来只需要进一步化简 $\Psi_t \mathbf{Q}_{t-1}$ 一项。由式 (3-21) 与式 (3-15) 可得

$$\Psi_t \mathbf{Q}_{t-1} = \Psi_{t-1} \mathbf{Q}_{t-1} - \Psi_{t-1} \mathbf{X}_t^\top (\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top)^{-1} \mathbf{X}_t \Psi_{t-1} \mathbf{Q}_{t-1} \quad (3-25)$$

$$= \hat{\Phi}_{t-1} - \Psi_{t-1} \mathbf{X}_t^\top (\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top)^{-1} \mathbf{X}_t \hat{\Phi}_{t-1}. \quad (3-26)$$

接下来要证明如下恒等式成立:

$$\Psi_{t-1} \mathbf{X}_t^\top (\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top)^{-1} = \Psi_t \mathbf{X}_t^\top. \quad (3-27)$$

为此, 记

$$\mathbf{K}_t = (\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top)^{-1}. \quad (3-28)$$

由

$$\mathbf{I} = \mathbf{K}_t^{-1} \mathbf{K}_t = (\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top) \mathbf{K}_t, \quad (3-29)$$

可以推出

$$\mathbf{K}_t = \mathbf{I} - \mathbf{K}_t \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top. \quad (3-30)$$

进而

$$\Psi_{t-1} \mathbf{X}_t^\top \mathbf{K}_t = \Psi_{t-1} \mathbf{X}_t^\top (\mathbf{I} - \mathbf{K}_t \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top) \quad (3-31)$$

$$= (\Psi_{t-1} - \Psi_{t-1} \mathbf{X}_t^\top \mathbf{K}_t \mathbf{X}_t \Psi_{t-1}) \mathbf{X}_t^\top. \quad (3-32)$$

对照式 (3-21) 可知, 上式右端恰为 $\Psi_t \mathbf{X}_t^\top$, 故而式 (3-27) 得证。

再把式 (3-27) 代回式 (3-26), 便有

$$\Psi_t \mathbf{Q}_{t-1} = \hat{\Phi}_{t-1} - \Psi_t \mathbf{X}_t^\top \mathbf{X}_t \hat{\Phi}_{t-1}. \quad (3-33)$$

最后把式 (3-33) 代入式 (3-24), 立即得到

$$\hat{\Phi}_t = \left[\hat{\Phi}_{t-1} - \Psi_t \mathbf{X}_t^\top \mathbf{X}_t \hat{\Phi}_{t-1} + \Psi_t \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \quad \Psi_t \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \right], \quad (3-34)$$

即式 (3-13)。也就是说, 借助上一阶段统计量与当前阶段数据所得到的递归更新结果, 与直接访问全部历史样本所得到的联合训练闭式解完全一致, 定理因此得证。□

3.5 持续学习闭式求解算法

为了方便后文使用, 将上文推导总结为一个完整的递归岭回归闭式求解持续学习算法 3.1。该算法以阶段作为基本处理单位, 在第一阶段完成编码器学习并令统计量初始化为 $\Psi_0 = (\gamma \mathbf{I})^{-1}$, $\hat{\Phi}_0 = \mathbf{0}$; 之后每一轮只用本轮数据 $\mathcal{D}_t$ 以及上一轮得到两组紧凑统计量 $(\Psi_{t-1}, \hat{\Phi}_{t-1})$ 进行更新从而获得新的 $(\Psi_t, \hat{\Phi}_t)$, 然后就可以删除该轮所有原始样本满足无历史样本回放。

第四章针对四类任务给出的应用方法都可看作算法 3.1 在不同的特征表示方式下进行实现的具体情况虽然有所不同, 但其基本思想是一致的。

算法 3.1 递归岭回归闭式解持续学习（统一算法）

Require: 阶段序列 $t = 1, 2, \dots, T$; 正则化系数 $\gamma > 0$; 编码器 f_θ

- 1: **初始化:** $\Psi_0 \leftarrow (\gamma \mathbf{I})^{-1}$, $\hat{\Phi}_0 \leftarrow \mathbf{0}$
 - 2: 以监督学习方式在 $\mathcal{D}_1$ 上训练编码器 f_θ , 随后冻结其参数
 - 3: **for** 阶段 $t = 1$ **to** T **do**
 - 4: 提取特征矩阵: $\mathbf{X}_t \leftarrow f_\theta(\mathcal{D}_t)$
 - 5: 构造分块标签: $\mathbf{Y}_t \leftarrow [\bar{\mathbf{Y}}_t, \tilde{\mathbf{Y}}_t]$
 - 6: {借助 Woodbury 恒等式更新逆自相关矩阵}
 - 7: $\Psi_t \leftarrow \Psi_{t-1} - \Psi_{t-1} \mathbf{X}_t^\top (\mathbf{I} + \mathbf{X}_t \Psi_{t-1} \mathbf{X}_t^\top)^{-1} \mathbf{X}_t \Psi_{t-1}$
 - 8: {按定理 3.1 更新解析分类头}
 - 9: $\hat{\Phi}_t \leftarrow \begin{bmatrix} \hat{\Phi}_{t-1} - \Psi_t \mathbf{X}_t^\top \mathbf{X}_t \hat{\Phi}_{t-1} + \Psi_t \mathbf{X}_t^\top \bar{\mathbf{Y}}_t & \Psi_t \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \end{bmatrix}$
 - 10: 释放 $\mathcal{D}_t$, 只保留紧凑统计量 $(\Psi_t, \hat{\Phi}_t)$
 - 11: **end for**
 - 12: **return** 最终的解析分类头 $\hat{\Phi}_T$
-

3.6 算法分析

从结果形式可以看出, 递归岭回归闭式解只需保存两项内容即可: 一个是解析分类头 $\hat{\Phi}_{t-1}$; 另一个是逆自相关矩阵 Ψ_{t-1} 。因此, 在 t 时刻进行更新时无需访问之前的数据点, 也无需对之前的任务进行反向传播梯度下降更新, 算法中增量部分主要是矩阵乘法以及矩阵求逆操作, 而矩阵求逆仅需对于大小为 $d \times d$ 的统计量求逆, 这与总的样本数无关, 这也是这种方法能够在大量任务上获得良好的性能的原因所在。

从时间复杂度考虑, 如果当前阶段的样本数量为 N_t , 那么求 $\mathbf{X}_t^\top \mathbf{X}_t$ 所需的代价为 $O(N_t d^2)$, 更新 Ψ_t 的主要成本在于求逆运算, 即 $O(d^3)$; 而对分类头 $\hat{\Phi}_t$ 进行更新需要多次矩阵相乘, 其总代价为 $O(d^2 N_t + d N_t^2 + d^2 d_{C_t})$, 与特征维度 d 、当前阶段样本数 N_t 以及到目前为止已经出现的所有类别数目 d_{C_t} 都有关系。由于以上工作都可以在 GPU 上快速完成计算, 因此本方法一般情况下要比基于多轮梯度下降反向传播不断优化的学习机制更快。

从空间复杂度上考虑, 该算法需要存储的内容主要是 $\Psi_t \in \mathbb{R}^{d \times d}$ 、当前的数据矩阵 $\mathbf{X}_t \in \mathbb{R}^{N_t \times d}$ 、分类头 $\hat{\Phi}_t \in \mathbb{R}^{d \times d_{C_t}}$, 因此总的所需空间大约是 $O(d^2 + d N_t + d d_{C_t})$, 其中 $O(d^2)$ 用于存储 Ψ_t , $O(d N_t)$ 用于存储特征矩阵 $\mathbf{X}_t$, $O(d d_{C_t})$ 用于存储分类头 $\hat{\Phi}_t$ 。更重要的是这种开销只会随着出现的类别数量增加而增加, 不是随着样本数量的增加而增加, 也就解决了回放缓存日益增大问题。

此外, 该框架还具有隐私保护的特点, 该方法不会保存任何历史原始样本, 仅保存

统计量矩阵，因此比较适合医疗数据等隐私要求较高的情况。下面给出隐私保护性质的形式化陈述与证明。

定理 3.2 (隐私保护性) 给定逆自相关统计量 Ψ ，无法通过逆向工程唯一地重建原始数据矩阵 $\mathbf{X}$ ，从而保证了原始样本的隐私。

证明 证明的关键是 Ψ 只与数据二阶协方差信息有关即 $\mathbf{X}^T \mathbf{X}$ ，而不包含原始样本的具体取值。设 $\mathbf{X}^T \mathbf{X} = \mathbf{A}$ ，则满足此等式的 $\mathbf{X}$ 不是唯一的，有无穷多个可能的结果，即对于所有满足正交性条件 $\mathbf{U}^T \mathbf{U} = \mathbf{I}$ 的正交矩阵 $\mathbf{U}$ ，令变换后的矩阵 $\mathbf{X}' = \mathbf{U} \mathbf{X}$ ，那么就有

$$(\mathbf{X}')^T \mathbf{X}' = \mathbf{X}^T \mathbf{U}^T \mathbf{U} \mathbf{X} = \mathbf{X}^T \mathbf{X} = \mathbf{A}. \quad (3-35)$$

即 $\mathbf{X}'$ 与原始 $\mathbf{X}$ 对应同一个 Ψ 。因此，仅凭 Ψ 至多只能将 $\mathbf{X}$ 确定到一个正交变换的等价类，无法还原出原始数据本身，定理得证。□

这一节提供的递归闭式解可以看作是第四章针对四种应用提出的相应解决方案的核心思想。

3.7 本章小结

本章从理论上给出了闭式解持续学习的一般框架。首先将编码器被冻结后仅分类头的学习看作一个岭回归问题并求出联合训练条件下的最优解；然后定义逆自相关矩阵和标签分块形式将上述最优解用不需要访问所有原始的历史样本的形式进行表达；接着利用一系列矩阵恒等变换及推导证明这两种形式是等价的。即说明：在持续学习过程中我们完全可以不用反向传播而是通过保存少量统计数据就可以得到高效、鲁棒并且对隐私友好的解析式更新方法。而在下一章中将会详细探讨这种算法如何应用于实际问题中如医学图像疾病的识别、时间序列分类、语义分割以及多模态的大语言模型等。

第 4 章 面向多场景持续学习的闭式求解算法应用

第三章构建了递归岭回归闭式解的统一数学基础，给出了仅借助上一阶段统计量与当前阶段样本就能完成更新的递推公式，并证实其与联合训练解析解严格等价。本章将在该理论之上，针对四类典型的持续学习任务给出对应的应用方法。4.1 节围绕医学图像疾病分类展开，处置临床场景中类别持续扩展与隐私约束同时存有的问题；4.2 节转入时间序列分类，应对时序数据里的类内变化对持续学习所带来的额外挑战；4.3 节讨论语义分割，把闭式解从图像级分类推广到二维图像与三维点云的稠密预测，缓解类增量分割中的语义漂移问题；4.4 节落到多模态大语言模型专家路由这一应用上，把闭式解扩展到多专家的路由问题。这四类应用方法之间共享统一记号、统一推导与统一更新公式，差异主要映射在编码器选择、特征表示构造以及监督信号设计上。各节方法的相关研究成果已经整理为对应的论文，并在节首脚注中给出标注。

4.1 基于闭式求解的医学影像疾病分类¹




图 4-1 闭式解持续学习方法在医学图像疾病分类中的三个主要组成部分：(a) 基于反向传播（Back-Propagation, BP）的训练，使用主干网络和 Softmax 分类器做多轮训练；(b) 基于解析学习的第一阶段重对齐，把原分类器替换为解析分类器并与主干网络对齐，其中缓冲层是高维扩展层，通过最小二乘计算并保存特征的最优解；(c) 和 (d) 基于闭式解的持续学习，借助第三章的递归岭回归闭式解（算法 3.1）来更新解析分类头，本节将其简称为 C-RLS（Concatenated Recursive Least Squares）。

¹本节工作发表在 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP, CCF-B)，论文题为“AIDC: Benchmark for Analytical Learning in Incremental Disease Classification”。

4.1.1 场景特点与方法适配

医学图像疾病分类的持续学习可看作类别增量学习在临床视觉任务上的具体落地。设第 t 个增量学习阶段的医学图像数据集为

$$D_t = \{\mathbf{X}_t, \mathbf{Y}_t\}, \quad (4-1)$$

其中 $\mathbf{X}_t \in \mathbb{R}^{N_t \times C \times H \times W}$ 是输入的医学图像张量, N_t 为样本数量, C 、 H 、 W 分别为图像的通道数、高度和宽度; $\mathbf{Y}_t$ 为对应的独热编码真值矩阵。与一般视觉分类任务相比, 医学图像持续学习主要呈现以下三个特点。

第一是隐私约束更强。无论病理图像、血液细胞图像还是器官组织切片, 都有可能携带敏感的个人健康信息, 故而直接保存历史样本用于回放往往会受到较大限制。

第二是类别扩展更频繁。伴随临床知识更新和采集范围扩大, 新疾病亚型、新病程阶段乃至新的采集模态会陆续加入已有系统, 要求模型具备较好的长期可扩展性。

第三是样本分布更不平衡。医学数据中不同疾病的发生频率往往相差悬殊, 少数类和难分类常常同时浮现, 这会进一步放大增量学习中的类别偏置问题。

以上三点正好符合第三章递归岭回归闭式解的特点: 闭式解只需要统计量而不需要查看任何历史样本, 自然可以解决医学数据隐私的问题; 其递归更新公式可以在有新的疾病亚型时进行有效的增量更新, 不需要再次训练之前的所有类别, 正好对应类别频繁增”的情况; 保存的相关统计量从理论上来看与联合训练的效果一样, 对于类别不平衡造成的判别边界的变化具有良好的鲁棒性。因此本章就直接以第三章的方法为基础, 给出一种用于医学图像疾病的解析类增量学习的方法。

4.1.2 总体框架

如图 4-1 所示, 本节的方法包括基础编码器训练、对齐以及解析持续学习三个部分。在该任务上它也分为三步进行。

第一阶段是基础编码器训练。模型在初始任务上以常规监督学习的方式训练特征提取网络, 使其获得可迁移的表征能力。

第二阶段是解析对齐, 在完成训练后用原来的软最大分类头替换为解析分类头并利用最小二乘或者岭回归将编码器输出与标签空间进行对齐从而获得闭式解分类器。

第三阶段是解析持续学习, 在有新的任务出现时, 将编码器固定住, 只用当前的任务特征以及上一步得到的统计量进行分类头更新的操作, 不再用反向传播的方法对分类器多次优化, 这个过程与第三章中的递归岭回归是相同的, 因此可以得到一样的结果。即本部分使用第三章中的定理 3.1。

这样设计使得闭式解持续学习方法比传统的增量学习方法具有两个显著优势: 一个方面是由于历史知识是以统计量的形式被明确地存储而不需要通过梯度约束或者样本

回放进行隐式的记忆因此其遗忘程度更低；另一个方面是在增量过程中一般只需要一次遍历现有数据集即可实现更新从而更快。

4.2 基于闭式求解的时间序列分类²




图 4-2 所提 TS-ACL 方法总体框架。(a) 先在任务 1 上通过基于梯度下降的训练得到预训练编码器；(b) 接着在分类头前面引入带随机隐藏层模块，用以增强特征维度；(c) 最后在跨任务过程中使用递归岭回归学习机制。

4.2.1 场景特点与方法适配

时间序列样本一般是在时间维度上由多个通道传感器连续获取得到，在健康监护、工业设备故障检测、人机交互以及行为分类等领域都有大量应用。用表示第 t 个时间序列增量学习任务数据集为

$$D_t = \{\mathbf{X}_t, \mathbf{Y}_t\}, \quad (4-2)$$

其中 $\mathbf{X}_t \in \mathbb{R}^{N_t \times c \times l}$ 是输入时间序列张量， c 为通道数， l 为时间长度， $\mathbf{Y}_t$ 则是独热编码真值矩阵。各任务的类别集合互不交叠，模型完成第 t 个任务的学习之后，需要对所有已经见过的类别做统一分类。

时间序列持续学习除了灾难性遗忘之外，还有一个更突出的特点——类内变化明显：同一类别在不同个体、不同设备甚至不同环境下都可能呈现出截然不同的动态模

²本节工作发表在 Knowledge-Based Systems (KBS) 期刊审稿中，论文题为“TS-ACL: Closed-Form Solution for Time Series-oriented Continual Learning”。

式。例如，同一种行为在不同人的传感器数据中可能展现出不同的节奏、幅值与局部形状；同一种手势在不同佩戴方式下也可能表现出不同的时间结构。这就意味着模型既要学习不同类别之间的差异，也要建模类别内部的多样性。

由于这种特点，传统的基于少量回放样本的方式具有不可避免缺陷：当类内的变化比较丰富时，规模较小的缓存不能包含所有的变化情况。而第三节提出的递归岭回归闭式解正好适合这种情况——解析分类头部利用权重统计量学习类内分布，无需在缓存中存储数据就可以学到整个类内的变化情况；新的类别出现只需进行一次解析的更新即可增加一个判别子空间，防止遗漏类内多样性。本节就在这个基础上结合时间序列的特点加入多尺度特征融合以及随机高维映射来提高对局部波动性和长程依赖性的建模能力。

4.2.2 总体框架

如图 4-2 所示，本文提出的方案可以分为预训练编码器、随机高维映射以及递归岭回归学习三个部分。针对时间序列内部差异较大，在固定编码器后鲁棒性有限的问题，在第三章的基础上提出了三个改进措施：多尺度特征聚合（既包括浅层局部波形也包括深层语义信息）、随机高维映射（提高解析分类头线性可分性）和集成扩展（进一步提高性能），都旨在实现稳定性和灵活性并存。

这个框架整体上与第三章相同，仍然采用先训练编码器，在此基础上固定编码器然后不断迭代解析分类头的方式进行。不同之处在于为了更好地捕捉时间序列中的局部信息以及长距离依赖，在提取特征时加入了多尺度特征融合的方法。

具体地，先在第一个任务上训练一维卷积编码器，让其获得基础的时序表示能力。训练完成之后冻结编码器参数。对单个输入样本 $\mathbf{X}^n$ ，把编码器第 k 层的输出特征记为 $\mathbf{X}^{\text{feat},k,n} = f_k(\mathbf{X}^n)$ ，并把同一任务内所有样本在该层的特征沿样本维度堆叠成矩阵 $\mathbf{X}_t^{\text{feat},k}$ 。不同层的特征映射的是不同时间尺度的信息：浅层更倾向于局部波形模式，深层则更倾向于全局语义表征。旨在强化后续解析分类头的表示能力，本节并不只用最终层特征，而是把多层特征拼接起来，得到

$$\mathbf{X}_t^{\text{stack}} = \text{Concat}(\mathbf{X}_t^{\text{feat},1}, \dots, \mathbf{X}_t^{\text{feat},K}). \quad (4-3)$$

在此基础上，再借助随机初始化的隐藏层做一次高维映射：

$$\mathbf{X}_t^E = \text{ReLU}(\mathbf{X}_t^{\text{stack}} \mathbf{R}^E), \quad (4-4)$$

式中 $\mathbf{R}^E \in \mathbb{R}^{d \times d_E}$ 为随机初始化矩阵， d_E 为高维映射的维度（也就是随机隐藏层宽度）， $\mathbf{X}_t^E$ 即为输入解析分类头的高维数据表示。最后，再用第三章的递归岭回归闭式解去更新分类头参数，由此达成对新类别的快速吸收。

4.2.3 集成扩展

为了更好地提高对于类内变化鲁棒性，在此把该方法推广到集成形式，记为 TS-ACL-E。其核心思想是借助随机隐藏层本身的随机性来构造多个相互独立的高维特征空间，保持预训练编码器、多尺度特征拼接以及递归岭回归更新方式都不变，只对随机隐藏层使用不同的随机种子做多次独立初始化，由此得到一组结构相同但映射方式各异的随机映射矩阵 $\{\mathbf{R}^{E,1}, \mathbf{R}^{E,2}, \dots, \mathbf{R}^{E,M}\}$ 。每一份随机初始化对应一个独立的解析分类头，并按照前述递推方式在所有任务上分别完成增量更新，最终得到 M 个并列的解析分类器。

对于一个单独测试样本 $\mathbf{x}^{\text{test}}$ 来说，先由各个解析分类头独立给出其在类别 c 上的预测得分，然后使用 softmax 将其转化为概率 $P_i(c | \mathbf{x}^{\text{test}})$ ，其中 $i \in \{1, \dots, M\}$ 是分类器编号；之后对所有分类器计算它们的概率求和并取其最大值所对应的类别即为预测结果。

$$\hat{y} = \arg \max_c \frac{1}{M} \sum_{i=1}^M P_i(c | \mathbf{x}^{\text{test}}). \quad (4-5)$$

由于各分类头共享同一冻结编码器与同样的递归岭回归更新规则，因此整体计算开销仅以倍数形式随 M 线性增加，并不会引入额外的反向传播；同时不同随机种子下的高维映射相当于对解析分类头的判别空间做了多视角投影，使其更不容易被某一个特定的随机方向所主导。这种集成扩展能够在不改变主体结构的前提下进一步增强模型对类内多样性的鲁棒性，尤其适用于子模式分布较为丰富的时间序列数据集。

4.2.4 闭式解为何适合时间序列

时间序列类内变化问题可以看成是从分布学习角度出发考虑。将同一类别的样本视为由许多不同的个体或者子模式所构成，则真实的分布一般由几个子簇组成。由于样本数量有限，在此情况下可能不足以包含所有的子簇；而闭式解方法是通过对所有已知样本进行统计计算求得最佳结果，因此有利于获得整个分布的信息。

从理论上说，第三章所提出的递归更新结果与联合训练是等价的。而这意味着，在编码器特征足够稳健的情况下，解析分类头就可以在不查阅过往样本的情况下达到查看所有过往样本之后的决策边界。而对于时间序列问题来说，这一点很重要，因为在其中模型可以通过保存历史统计量的方式来保存类别内部的变化而不是通过有限数量的回放样本来近似这些变化。

另一方面，冻结编码器会降低模型学习新类别能力，在此我们采用三种方法加以改进：第一是随机高维映射，通过增加特征线性可分性从而提高解析分类头灵活性；第二是多尺度特征融合，结合浅层与深层特征以更好地保持局部时序形态以及整体语义信息；第三是集成扩展，借助不同随机种子初始化的随机隐藏层得到多个并列的解析分类

头从判别空间多样性的角度进一步增强对类内多样性的鲁棒性。

4.3 基于闭式求解的语义分割³




图 4-3 所提方法 CFSSeg 的总体框架。第 t 步中，模型借助第 $t-1$ 步的模型通过伪标签机制生成伪标签，并与真实标签融合形成混合标签。模型继承第 $t-1$ 步学到的分类头 $\hat{\Phi}_{t-1}$ ，再结合混合标签、提取出的高维特征矩阵以及第 $t-1$ 步的 Ψ_{t-1} 。随后使用第三章的递归岭回归闭式解算法做更新，得到 $\hat{\Phi}_t$ 与 Ψ_t 。

4.3.1 场景特点与方法适配

语义分割任务在持续学习场景下展现出与图像级分类很不一样的特点。设输入样本既能够是二维图像，也可以是三维点云。第 t 个增量阶段的输入空间记为

$$\mathbf{X}_t \in \mathbb{R}^{N_t \times C_{in}}, \quad (4-6)$$

式中 N_t 是像素数或点数， C_{in} 为输入通道维度。输出标签空间记为

$$\mathbf{Y}_t \in \mathcal{C}_t^{N_t}, \quad (4-7)$$

其中 $\mathcal{C}_t$ 是截至第 t 阶段已经见过的类别集合，包含背景类 c_b 。与分类任务不同的是，语义分割所预测的是每个位置的类别 logits（即 softmax 之前的未归一化得分），基于此模型的输出为

$$q_{\theta_t}(\mathbf{X}_t) \in \mathbb{R}^{N_t \times |\mathcal{C}_t|}, \quad (4-8)$$

最终分割结果由每个位置取最大响应类别得到。

³本节工作发表在 ACM International Conference on Multimedia (ACM Multimedia / ACM MM, CCF-A)，论文题为“CFSSeg: Closed-Form Solution for Class-Incremental Semantic Segmentation of 2D Images and 3D Point Clouds”。

在类增量语义分割中，在第 t 个时期引入一个新的类别集 S_t ，并且在不同的时期引入的不同类别的集合不能有交集。根据训练注释的方式不同可以分为三类情况，这是本工作的第二个特点。

第一种是顺序设定。该设定下当前阶段的数据同时包含旧类别和新类别的标注，故而增量学习的难度相对较低，但仍需要避免参数更新破坏已有类别的判别边界。

第二种是不相交设定。该设定下当前阶段只显式标注新类别，旧类别在当前数据中被统一标为背景。由于旧类别并未真正消失，而是被错误地映射到背景类中，所以模型在增量训练之后容易把旧类别的语义吸收进背景，进而催生语义漂移。

第三种是重叠设定，在此背景下，背景标签不仅有可能是真实的背景，还可能是旧类别的甚至是还没有出现的新类别的表示方式，因此相比于互斥设定更加困难，模型需要学习新的类别同时又不能把背景中的旧的知识全部抹去。

除了标注方式差异之外，与传统基于梯度的持续学习方法相比，语义分割任务的持续学习还在以下三个方面表现得更为突出：稠密预测带来的稳定性与可塑性矛盾更尖锐、像素级或点级反向传播的计算成本更大、背景标签语义不稳定引致的语义漂移更难应对。这构成本场景的第二个特点。

根据以上特性，第三章提出的递归岭回归闭式解可以很好地解决这些问题：将稠密预测位置级别特征作为线性回归输入后，分类头更新即变为求解过程，从而不需要在每个像素或者每个点上进行一次反向传播，这与计算开销大的问题相对应；闭式解的递归形式也相当于联合训练，所以分类边界的确定只与累计统计数据有关而与梯度的方向无关，在不断更新的过程中仍然很鲁棒，这也符合稳定性和灵活性之间的矛盾突出。同时利用伪标签的方法用上一轮迭代得到的模型给背景像素重新打上标签，就可以恢复出之前由于被映射到背景而导致消失的旧类别的标注信息，从而减小了非交集以及重叠情况下出现的语义漂移，在此基础上我们提出一种适用于二维图像以及三维点云的一致闭式解持续语义分割方法。

4.3.2 总体框架

如图 4-3 所示，本文方法可分为冻结编码器、随机高维映射、递归岭回归闭式解更新新分类头三个步骤，在此基础上利用伪标签重构之前被映射到背景的旧类别监督。其主要思想是将一个语义分割网络分为稳定编码器和递归解析分类头。即在第一阶段用标准有监督方式训练分割编码器得到最基本的视觉表示能力；从第二阶段开始就不再优化编码器参数，而是利用编码器提取出特征进行分类头的解析性更新。这是因为希望在持续学习过程中只允许分类头发生改变以防止其对先前学到的知识产生影响。

但是，仅仅冻结编码器可以提高鲁棒性，但是会降低模型对新类别的灵活性，在此

基础上为了解决这个问题，在分类头之前添加了一个随机初始化隐藏层，将编码器输出映射到一个更大的特征空间上，在高维空间里有更强的线性可分性，通过随机映射以及非线性激活后，旧类别与新类别一般更易被线性分类器区分，因此即使编码器不再更新，解析分类头仍然有较好的泛化能力。

在这一基础上，在本节中直接用第三章递归岭回归闭式解来更新分类头。为了方便整个文章统一，用第 t 阶段编码器输出以及经过高维映射的数据集分别表示为

$$\mathbf{X}_t^E = \text{ReLU}(\mathbf{X}_t^{\text{encoder}} \mathbf{R}^E), \quad (4-9)$$

式中 $\mathbf{X}_t^{\text{encoder}}$ 为冻结编码器所提取的位置级特征， $\mathbf{R}^E$ 为随机初始化的映射矩阵。这样一来，语义分割分类头的更新就能直接套用式 (3-13)，只需要把该式中的数据矩阵换成 $\mathbf{X}_t^E$ ，也就是仅借助上一阶段的统计量与当前阶段的样本完成递推，并不需要访问任何历史原始数据。

4.3.3 二维图像与三维点云统一建模

本节方法对二维图像与三维点云都适用，其统一性可从以下三个层面来体会。

第一，在输入形式上：虽然二维图像用规则网格表达、三维点云用无序点集表达，但是通过编码器处理后两者都可以转化为位置级别的特征集，因此都可以表示为矩阵形式进入高维映射层。

其次是在学习目标方面：这两种任务都可以看成是对位置级特征进行类别分配的问题，因此都可以认为是对位置样本进行多类线性回归或者线性判别，正好可以用岭回归闭式解来学习解析分类头。

最后在持续学习更新方式方面：不管是像素级预测还是点级预测，分类头的增量更新都可以归结为第三章中给出的逆自相关矩阵 Ψ_t 以及权重矩阵 $\hat{\Phi}_t$ 的递推过程。也就是说，不同的模态只在于它们所对应的编码器结构及伪标签生成的方法不同，但是增量更新的方式是一样的。

从实现上看，在二维图像实验中使用 DeepLabv3 作为基本分割网络^[23]，骨干网络为 ResNet-101^[18]；而在三维点云实验中采用 DGCNN（动态图卷积神经网络）做为编码器^[24]。两种类型的模型在开始阶段都是通过传统的有标签的数据进行预训练，在之后增量阶段都换成解析分类头更新方式。这样使得该方法在不同的模态下有相同的基本原理以及良好的工程可迁移性。

4.3.4 二维图像伪标签策略

在不相交和重叠设定下，当前阶段训练标签中可能有大量背景像素其实属于旧类别。如果直接把这些像素全部当作背景送入训练，那么虽说闭式解分类头不会因梯度更

新而遗忘——但其回归目标本身已经发生偏移，依旧会使旧类别的语义向背景类塌缩。故而必须借助上一阶段的模型对背景像素做再判断。

把第 $t-1$ 阶段模型在位置 i 上的输出记为 $q_{\theta_{t-1}}(i, c)$ (softmax/sigmoid 前的未归一化得分，即 logit)，则该位置的不确定性定义为

$$U^i = 1 - \sigma \left(\max_c q_{\theta_{t-1}}(i, c) \right), \quad (4-10)$$

其中 $\sigma(\cdot)$ 是 Sigmoid 函数。式 (4-10) 首先将 logit 通过 sigmoid 映射到 $(0, 1)$ 的范围，得到这个位置上最大的类别置信度，然后用“1- 置信度”来表示不确定性大小，如果最大响应值越大，则说明原来的模型对于这个点是比较确定的，此时对应的位置不确定性就越小；否则就是该点处于真实的背景或者难以区分的地方。

由此，二维图像的伪标签可定义为

$$\tilde{Y}_t^i = \begin{cases} Y_t^i, & Y_t^i \in S_t, \\ Y_t^i, & (Y_t^i = c_b) \wedge (U^i > \tau), \\ \hat{Y}_{t-1}^i, & (Y_t^i = c_b) \wedge (U^i \leq \tau), \end{cases} \quad (4-11)$$

其中 τ 是阈值，在新标签中将一个像素标记为背景的情况下，如果旧模型对该像素有较高的置信度，则用旧模型对该像素的分类结果来取代背景标签；而当旧模型对该像素缺乏信心时就维持它原来的背景标签。这种方法实际上是：在不需要任何先前的真实图像的情况下，在现有样本中发现潜在的老类别的监督信息从而解决语义漂移问题。

4.3.5 三维点云伪标签策略

对于三维点云而言，由于每一点周围都是稀疏点云，因此单点预测更易受到局部稀疏性以及邻域扰动的影响，在生成点云伪标签的同时考虑邻域信息。对于点 i ，首先根据其空间位置找到其最近的 K 个邻居，然后根据它们的空间位置确定邻域权重 w_k ，最后利用上一步获得模型预测值以及邻域加权分布估计出该点的不确定性，本文使用一种基于空间不确定性度量方法可以表示为

$$U^i = - \sum_c \left[\frac{1}{K} \sum_k q_{t-1}(i, c) w_k \right] \log \left[\frac{1}{K} \sum_k q_{t-1}(i, c) w_k \right] + \frac{1}{K} \sum_{c,k} (q_{t-1}(i, c) w_k) \log (q_{t-1}(i, c) w_k). \quad (4-12)$$

相应地，点云伪标签的规则为

$$\tilde{Y}_t^i = \begin{cases} Y_t^i, & Y_t^i \in S_t, \\ \hat{Y}_{t-1}^i, & (Y_t^i = c_b) \wedge (\hat{Y}_{t-1}^i \neq c_b) \wedge (U^i \leq \tau), \\ \hat{Y}_{t-1}^{i,k'}, & (Y_t^i = c_b) \wedge ((\hat{Y}_{t-1}^i = c_b) \vee (U^i > \tau)), \\ c_b, & \text{其他情况}, \end{cases} \quad (4-13)$$

式中 $\hat{Y}_{t-1}^{i,k'}$ 指代那些契合非背景且不确定性较低条件的近邻点预测类别。相比二维策略，三维点云方法不单顾及当前点自身的预测，还把邻域空间结构纳入顾及，由此更适合应对点云的局部稀疏性和几何连续性问题。

4.4 基于闭式求解的多模态大语言模型专家路由⁴

4.4.1 场景特点与方法适配

在多模态大语言模型持续学习中，专家路由任务相比于上面介绍的分类、回归及分割等任务有它特殊的应用背景，在实践中一般采用共享主干和任务专家的形式进行设计。将主干部分表示为 f_θ ，并且在整个持续学习中保持不变；而对于第 t 个特定任务，则使用相应的轻量级专家模块 E_t 。在训练时只需更新当前任务所对应专家的参数，在测试时需要一个路由器根据输入 $\mathbf{X}$ 选择最合适的专家。

把全部任务集合记为 $\mathcal{T} = \{1, 2, \dots, T\}$ ，那么路由器本质上要学习的就是一个从输入到任务编号的映射：

$$g : \mathbf{X} \rightarrow \{1, 2, \dots, T\}. \quad (4-14)$$

这一映射看上去简单，但在多模态终身学习场景中却展现出以下两个突出特点。

第一是特征空间高度复杂。图像、文本以及跨模态对齐信息共同决定任务分布，简单的相似度方法很难稳定地划分不同领域的边界。

第二是路由器自身也需要持续学习。一旦新任务持续到来，传统基于梯度训练的路由器自身也会浮现遗忘和重训练问题，这与本章前几节所讨论的持续学习矛盾在本质上是相同的；加之路由器一旦选错专家，即使专家本身完好，最终的响应也会失败，所以路由器的稳定性对整套系统的表现具有近乎决定性的影响。

根据以上特点，在第三章中递归岭回归闭式解正好满足需求：由于路由问题是数学意义上可以认为是从特征到专家编号的解析分类问题，因此主干输出的最后一层隐藏状态就可以作为高判别力的语义特征馈送到解析路由头；当有新的任务加入时只需要按照

⁴本节工作发表在 International Conference on Learning Representations Workshop (ICLR Workshop)，论文题为“CF-Router: Closed-Form Solution for Expert Selection in Multimodal Agent Lifelong Learning”。

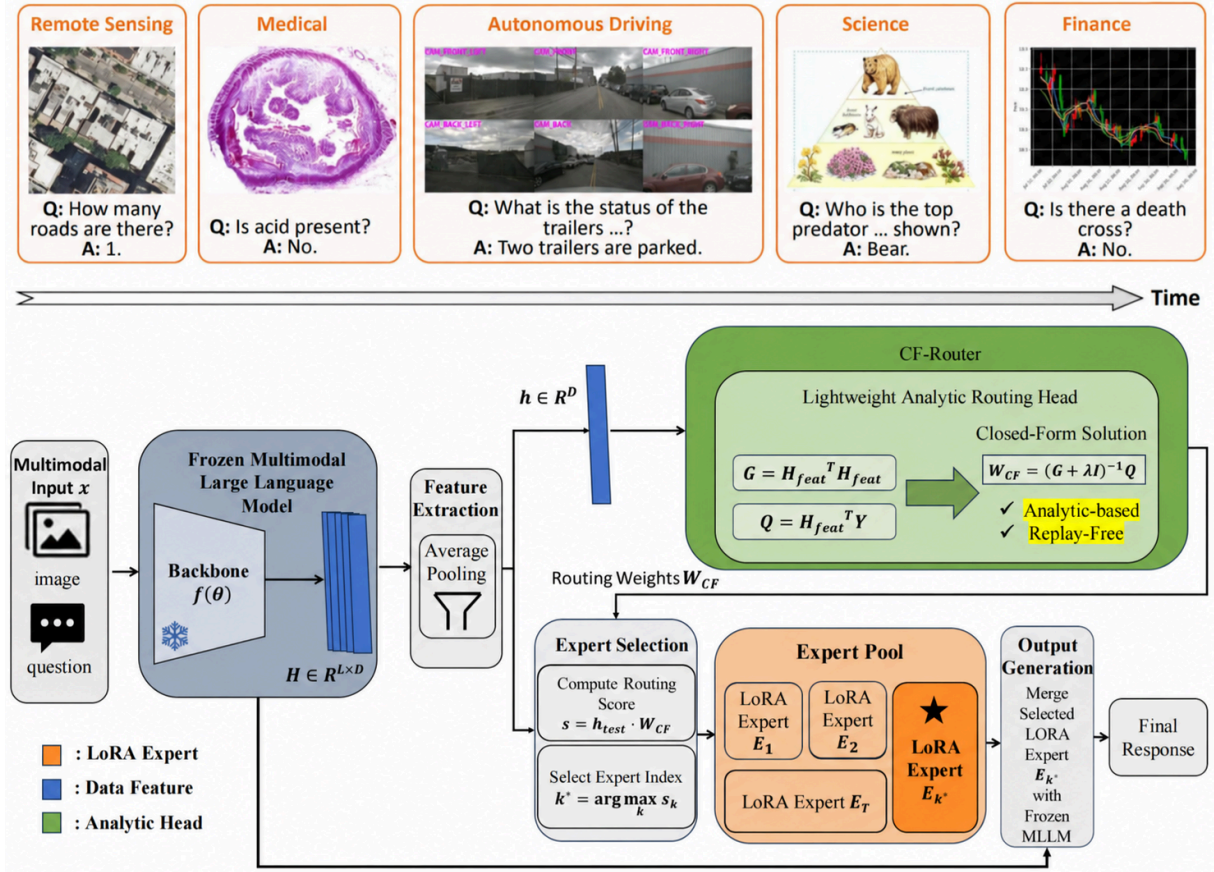


图 4-4 CF-Router 框架概览。上图：终身学习场景，涵盖遥感、医疗、自动驾驶、科学以及金融等不同领域任务，它们按时间顺序依次到达，每个领域都有自己的视觉问答数据（改编自 Zhao et al.^[28]）。下图：CF-Router 架构。多模态输入 x （图像与问题）由冻结的多模态大语言模型主干 f_θ 处理，生成隐藏状态序列 $X_{\text{seq}} \in \mathbb{R}^{L \times D}$ 。平均池化将序列压缩为固定大小的特征 $X_{\text{feat}} \in \mathbb{R}^D$ 。在训练期间，CF-Router 增量累积自相关矩阵 $G = \sum X_{\text{feat}}^T X_{\text{feat}}$ 与互相关矩阵 $Q = \sum X_{\text{feat}}^T Y$ ，接着解析地计算路由头 $\hat{\phi}_i = (G + \gamma I)^{-1} Q$ ，整个过程不需要任何梯度下降。在推理期间，计算路由得分 $s = X_{\text{feat}}^{\text{test}} \hat{\phi}_i$ ，再从专家池中挑出得分最高的专家 $k^* = \arg \max_k s_k$ 。被选中的 LoRA 专家 E_{k^*} 与冻结主干合并以生成最终响应。这一设计既是基于解析解的（路由无需反向传播），又是无回放的（不存储任何先前任务的数据）。

第三章给出的递推公式进行增量更新即可，无需对整个路由网络进行再训练，也无须重播之前的所有多模态数据集，从而实现稳定性和可伸缩性的兼顾。而本文提出方法正是基于此思想进行设计，即 CF-Router 方法。

4.4.2 总体框架

如图 4-4 所示，本节方法能够概括为多模态语义特征提取、路由头解析更新与专家训练、基于路由的推理三个阶段。CF-Router 在第三章统一框架的基础上，把专家路由的整体流程组织成三个阶段，并按算法 4.1 与算法 4.2 所给出的训练与推理过程做具体落地。

算法 4.1 基于 CF-Router 的终身学习（训练阶段）。本算法为统一框架（算法 3.1）在专家路由场景下的具体实例化：累积统计量 $\mathbf{G}$ 与第三章的 Ψ^{-1} 之间满足 $\mathbf{G} = \Psi^{-1} - \gamma \mathbf{I}$ ，互相关矩阵 $\mathbf{Q}$ 与第三章 $\mathbf{Q}_i$ 同义；最终路由头 $\hat{\Phi}_t = (\mathbf{G} + \gamma \mathbf{I})^{-1} \mathbf{Q} = \Psi_t \mathbf{Q}_t$ 与定理 3.1 给出的递推结果严格等价。

Require: 任务序列 $\mathcal{T} = \{1, \dots, T\}$

Require: 冻结的多模态大语言模型主干 f_θ

Require: 正则化系数 γ ，用于自相关矩阵 $\mathbf{G}$ 与互相关矩阵 $\mathbf{Q}$ 的缓冲区

```

1: for 每个任务  $t \in \mathcal{T}$  及其数据集  $\mathcal{D}_t$  do
2:   初始化新的 LoRA 专家  $E_t$ 
3:   {阶段 1: 训练路由头}
4:   for  $\mathcal{D}_t$  中的每个批次  $(\mathbf{x}, \mathbf{y})$  do
5:     提取最后一层隐藏状态:  $\mathbf{X}_{\text{seq}} = f_\theta(\mathbf{x})$ 
6:     平均池化:  $\mathbf{X}_{\text{feat}} = \frac{1}{L} \sum_{i=1}^L \mathbf{X}_{\text{seq}, i}$ 
7:     构建任务  $t$  的独热编码专家编号目标  $\mathbf{Y}$ 
8:     更新自相关矩阵:  $\mathbf{G} \leftarrow \mathbf{G} + \mathbf{X}_{\text{feat}}^\top \mathbf{X}_{\text{feat}}$ 
9:     更新互相关矩阵:  $\mathbf{Q} \leftarrow \mathbf{Q} + \mathbf{X}_{\text{feat}}^\top \mathbf{Y}$ 
10:   end for
11:   {阶段 2: 训练专家}
12:   for  $\mathcal{D}_t$  中的每个批次  $(\mathbf{x}, \mathbf{y})$  do
13:     专家  $E_t$  前向传播:  $\hat{\mathbf{y}} = f_{\theta, E_t}(\mathbf{x})$ 
14:     计算大模型损失:  $\mathcal{L} = \text{CrossEntropy}(\hat{\mathbf{y}}, \mathbf{y})$ 
15:     通过反向传播更新  $E_t$  (让  $f_\theta$  保持冻结)
16:   end for
17:   {阶段 3: 解析更新路由头}
18:    $\hat{\Phi}_t = (\mathbf{G} + \gamma \mathbf{I})^{-1} \mathbf{Q}$ 
19:   存储/冻结专家  $E_t$ 
20: end for
```

第一阶段是多模态语义特征提取。冻结的多模态大语言模型主干 f_θ 接收图文混合输入并输出最后一层的隐藏状态序列，再经过平均池化得到一个固定维度的语义特征向量，作为解析路由头的输入；该阶段并不引入任何可学习参数，对应算法 4.1 中的特征抽取步骤。

第二阶段是路由头解析更新与专家训练。对当前任务 t 的每个批次，先把池化得到的特征累积到自相关矩阵 $\mathbf{G}' = \sum_{i \leq t} \mathbf{X}_i^\top \mathbf{X}_i$ 与互相关矩阵 $\mathbf{Q}' = \sum_{i \leq t} \mathbf{X}_i^\top \mathbf{Y}_i$ 中（与第三章

算法 4.2 CF-Router 推理过程

Require: 测试样本 $\mathbf{x}^{\text{test}}$

Require: 冻结的多模态大语言模型 f_θ , 路由头 $\hat{\Phi}_t$

Require: 专家池 $\mathcal{E} = \{E_1, \dots, E_T\}$

- 1: {步骤 1: 路由决策}
 - 2: 提取最后一层隐藏状态: $\mathbf{X}_{\text{seq}}^{\text{test}} = f_\theta(\mathbf{x}^{\text{test}})$
 - 3: 平均池化: $\mathbf{X}_{\text{feat}}^{\text{test}} = \frac{1}{L} \sum_{i=1}^L \mathbf{X}_{\text{seq},i}^{\text{test}}$
 - 4: 计算得分: $\mathbf{s} = \mathbf{X}_{\text{feat}}^{\text{test}} \hat{\Phi}_t$
 - 5: 选择专家索引: $k^* = \arg \max_k s_k$
 - 6: {步骤 2: 生成}
 - 7: 激活 LoRA 专家 E_{k^*}
 - 8: 生成响应: $\mathbf{y}^{\text{pred}} = f_{\theta, E_{k^*}}(\mathbf{x}^{\text{test}})$
 - 9: **return** $\mathbf{y}^{\text{pred}}$
-

$\mathbf{Q}_t$ 同义); 当前任务全部遍历完毕后, 按 $\hat{\Phi}_t = (\mathbf{G}^t + \gamma \mathbf{I})^{-1} \mathbf{Q}^t$ 求出新的路由分类头的参数。然后与此同时再继续针对当前任务初始化并训练相应的低秩适配专家 (LoRA) E_t , 主干网络冻结就好了。

第三阶段是基于路由的推理。给定测试样本, 先按照第一阶段的方式抽取语义特征, 接着用最新的路由头计算各专家的得分, 并取最大值得到专家编号 k^* , 最后激活相应的 LoRA 专家与冻结主干合并起来生成响应。整个流程在新任务接入时仅增多一次解析更新和一次专家训练, 既不需要回放任何历史多模态样本, 也不需要重训路由器, 因而天然支持长期增量。

4.4.3 多模态隐藏状态特征提取

对单个多模态输入样本 $\mathbf{X}^n$ 而言, 冻结的多模态大语言模型主干会先生成最后一层的隐藏状态矩阵:

$$\mathbf{X}_{\text{seq}}^n \in \mathbb{R}^{L \times D}, \quad (4-15)$$

式中 L 是序列长度, D 是隐藏维度。旨在得到一个可供解析分类头使用的固定长度表示, 本节对序列维度做平均池化:

$$\mathbf{X}_{\text{feat}}^n = \frac{1}{L} \sum_{i=1}^L \mathbf{X}_{\text{seq},i}^n, \quad (4-16)$$

其中 $\mathbf{X}_{\text{feat}}^n \in \mathbb{R}^D$ 。这一向量能够视为当前多模态输入的语义表示, 综合映射了图像内容、文本指令以及跨模态上下文信息。

与那些直接使用人工定义相似度度量的做法不同，最后一层隐藏状态是经过多模态大语言模型深层交互之后得到的高层语义表示，基于此对任务领域具备更强的判别能力。本节正是借助这一点，把专家路由问题转化为对隐藏状态特征的解析分类。

4.4.4 专家选择头的闭式解更新

在第三章统一记号下，把第 t 个增量阶段提取到的多模态语义特征矩阵记为

$$\mathbf{X}_t = \begin{bmatrix} \mathbf{X}_{\text{feat}}^1 \\ \mathbf{X}_{\text{feat}}^2 \\ \vdots \\ \mathbf{X}_{\text{feat}}^{N_t} \end{bmatrix} \in \mathbb{R}^{N_t \times D}, \quad (4-17)$$

对应的专家编号独热编码真值记为 $\mathbf{Y}_t \in \mathbb{R}^{N_t \times d_{C_t}}$ ，那么其中 d_{C_t} 是截至第 t 阶段累计的专家数。继续沿用第三章的记号，将路由分类头记作解析分类头 $\hat{\boldsymbol{\Phi}}_t$ ，其在联合训练条件下由带正则项的最小二乘问题可以得到：

$$\hat{\boldsymbol{\Phi}}_t = \arg \min_{\hat{\boldsymbol{\Phi}}} \left\| \mathbf{X}_{1:t} \hat{\boldsymbol{\Phi}} - \mathbf{Y}_{1:t} \right\|_F^2 + \gamma \left\| \hat{\boldsymbol{\Phi}} \right\|_F^2, \quad (4-18)$$

对应的闭式解为

$$\hat{\boldsymbol{\Phi}}_t = (\mathbf{X}_{1:t}^\top \mathbf{X}_{1:t} + \gamma \mathbf{I})^{-1} \mathbf{X}_{1:t}^\top \mathbf{Y}_{1:t}. \quad (4-19)$$

式 (4-19) 对应的就是多模态专家路由场景——标签由语义类别换成了专家编号，本质上依旧是一个解析可解的多类判别问题。

进一步地，本节直接继承第三章的递归更新方式，维护逆自相关矩阵

$$\boldsymbol{\Psi}_t = (\boldsymbol{\Psi}_{t-1}^{-1} + \mathbf{X}_t^\top \mathbf{X}_t)^{-1}. \quad (4-20)$$

就专家路由任务而言，第 t 阶段一般只会引入新的专家编号监督，所以式 (3-13) 中的旧类别监督项 $\tilde{\mathbf{Y}}_t$ 通常为零矩阵。由此，路由头的递推更新可写成

$$\hat{\boldsymbol{\Phi}}_t = \left[\hat{\boldsymbol{\Phi}}_{t-1} - \boldsymbol{\Psi}_t \mathbf{X}_t^\top \mathbf{X}_t \hat{\boldsymbol{\Phi}}_{t-1} \quad \boldsymbol{\Psi}_t \mathbf{X}_t^\top \tilde{\mathbf{Y}}_t \right], \quad (4-21)$$

其中 $\tilde{\mathbf{Y}}_t$ 是当前阶段新增专家所对应的真值子矩阵。若当前阶段同时包含对旧专家的监督，则能够直接运用第三章更一般的递推形式，把 $\tilde{\mathbf{Y}}_t$ 一并纳入更新即可。

当然也可以把上述递推理解为对二阶统计量的持续维护：

$$\mathbf{G}^t = \sum_{i=1}^t \mathbf{X}_i^\top \mathbf{X}_i, \quad \mathbf{Q}^t = \sum_{i=1}^t \mathbf{X}_i^\top \mathbf{Y}_i, \quad (4-22)$$

则 $\boldsymbol{\Psi}_t = (\mathbf{G}^t + \gamma \mathbf{I})^{-1}$ ，并且 $\hat{\boldsymbol{\Phi}}_t = \boldsymbol{\Psi}_t \mathbf{Q}^t$ 。

4.4.5 推理过程

推理阶段对测试输入样本 $\mathbf{X}^{\text{test}}$ 的应对如下：先依托式 (4-16) 提取其语义表示 $\mathbf{X}_{\text{feat}}^{\text{test}}$ ，再用路由头计算所有专家的得分：

$$\mathbf{s} = \mathbf{X}_{\text{feat}}^{\text{test}} \hat{\boldsymbol{\Phi}}_t. \quad (4-23)$$

最后挑出得分最高的专家编号：

$$k^* = \arg \max_k s_k. \quad (4-24)$$

被选择的专家和冻结主干一起产生最终的回答。由于路由头本身是一种非常轻量级的线性结构，在推理过程中的开销相对于主干的前向传播可以忽略不计，因此这种方法具有很好的实时性。

4.5 本章小结

本章基于第三章统一数学框架下，分别针对四种常见持续学习问题提出相应解决方案，在医学图像疾病分类中利用基础编码器训练、解析对齐以及解析增量学习三个步骤实现适用于隐私敏感以及类别不断增多情况下的解析增量学习方法；在时间序列分类中使用多尺度特征融合、随机高维映射和集成扩展使得闭式解具有鲁棒性并且能够处理类内变化；在语义分割中将解析分类头从图像级分类推广到稠密预测的二维图像分割及稠密预测的三维点云分割，并通过不同的伪标签方式消除不相交或者重叠区域之间的语义漂移；在多模态大语言模型专家路由中采用主干最后一层隐藏状态表示语义信息并用闭式解方式进行专家选择头优化从而无需梯度计算也无需重放数据进行有效路由。所有上述应用场景都源于第三章统一推导。

第 5 章 实验结果与分析

本章从一个统一的实验环境出发对第四章针对四种不同任务提出的方法进行比较研究。具体来说，在 5.1 节中我们对医学图像疾病分类任务进行测试，在 5.2 节中我们对时间序列分类任务进行测试，在 5.3 节中我们对二维图像以及三维点云语义分割任务进行测试，在 5.4 节中我们对多模态大语言模型专家路由任务进行测试，在 5.5 节中是本章总结部分。每个任务都是先介绍该任务的数据集及设置，然后介绍所使用的评价指标以及所采用的基线方法，最后展示我们的方法与其他方法相比所取得的效果以及效率等。

5.1 医学图像疾病分类实验

5.1.1 数据集与设置

为了系统地比较闭式解方法对于医学图像疾病分类的效果，在这里我们使用面向增量疾病分类的统一基准来进行实验研究。该基准从 MedMNIST v2^[8] 中选择了三个有代表性的多类疾病分类的数据集 BloodMNIST、PathMNIST 和 OrganAMNIST。为了让不同的持续学习的方法在一个相同的环境下进行比较，所有的图像都被调整到大小为 28×28 。

BloodMNIST 共有 8 个类别，其训练集、验证集与测试集规模分别是 11959、1712 和 3421；PathMNIST 共有 9 个类别，对应数据规模分别为 89996、10004 与 7180；OrganAMNIST 则有 11 个类别，训练集、验证集和测试集规模分别为 34561、6491 和 17778。出于构造类别增量学习流程，本节把三个数据集都划分成 4 个任务，并确保不同任务的类别两两不重叠。

表 5-1 MedMNIST 医学图像持续学习基准的数据划分与任务设置。本节遵循 MedMNIST 官方划分，并采用按任务划分类别（class-per-task）的持续学习设置，与已有研究^[9]保持一致。

数据集	训练集	验证集	测试集	类别数	每任务类别
BloodMNIST	11,959	1,712	3,421	8	[2, 2, 2, 2]
OrganAMNIST	34,561	6,491	17,778	11	[3, 3, 3, 2]
PathMNIST	89,996	10,004	7,180	9	[3, 2, 2, 2]

5.1.2 评价指标与对比方法

评价指标使用第 2 章 2.6 节定义的平均准确率 (ACC, 式 (2-7)) 以及平均遗忘率 (Forgetting, 式 (2-8)), 这两个指标分别对应持续学习中的可塑性与稳定性, 能比较全面地映射模型表现。

对比方法包含五类典型的持续学习基线: LwF^[37]、iCaRL^[26]、EWC^[29]、MAS^[36] 与 EEIL^[33]。同时把没有使用任何专门持续学习机制、只在当前任务上微调的 Naive 作为下界参考。所有方法都使用相同的骨干网络, 高维映射维度 d_E 设为 8192, 岭回归正则项系数 γ 设为 1, 并尽可能保留训练超参数一致, 以此保障比较的公平性。

5.1.3 主要结果分析

表 5-1 汇总了本节所取用的 MedMNIST 医学图像持续学习基准设置。在该设置之上, 如表 5-2 所示, 本文方法与各类经典持续学习基线在三个数据集上的最终对比结果如下。

表 5-2 MedMNIST 基准上的方法对比结果。评估指标为平均准确率 (Acc, $\uparrow$) 与平均遗忘率 (Forg, $\downarrow$), 本文方法在三个数据集上均取得最优结果。

类别增量学习						
方法	BloodMNIST		PathMNIST		OrganAMNIST	
	Acc $\uparrow$	Forg $\downarrow$	Acc $\uparrow$	Forg $\downarrow$	Acc $\uparrow$	Forg $\downarrow$
Naive	24.87	93.88	54.87	50.20	35.78	77.77
EWC ^[29]	24.41	66.41	49.38	54.58	34.40	76.76
MAS ^[36]	43.94	69.43	34.22	74.98	44.99	55.13
LwF ^[37]	27.29	91.71	54.83	50.10	34.76	79.15
EEIL ^[33]	24.46	94.86	46.68	61.40	31.62	79.04
iCaRL ^[26]	41.17	37.83	69.44	15.85	58.05	17.83
本文方法	79.84	9.64	73.55	9.06	60.55	11.56

实验结果展现, 闭式解持续学习方法在三个医学图像数据集上整体表现优于传统持续学习方法。以 BloodMNIST 为例, 本文方法的平均准确率达到 79.84%, 平均遗忘率为 9.64%; 与之相对, 传统方法里表现最好的 iCaRL 平均准确率为 41.17%, 平均遗忘率为

37.83%。这一结果表明，解析更新在维系旧类知识方面有相当明显的优势。

在 PathMNIST 数据集上，闭式解持续学习方法依旧保持领先，取得 73.55% 的平均准确率与 9.06% 的平均遗忘率，而传统基线中表现较好的 iCaRL 对应数值则分别为 69.44% 与 15.85%。这表明在病理图像这一类纹理复杂、类别间差异细微的数据上，闭式解分类头依旧能比较好地继承初始编码器的特征，并借助解析更新把历史知识保留下来。

在 OrganAMNIST 数据集上，各方法之间的差距相对收窄，但闭式解持续学习方法依旧占优——平均准确率达到 60.55%，高于 iCaRL 的 58.05%；平均遗忘率为 11.56%，明显优于大多数传统方法。

5.1.4 结果讨论

从整体上来看，解析方法最大的好处就是可以兼顾高准确率以及低遗忘。而以往的回放或者蒸馏都需要在鲁棒性和灵活性中做出权衡，在增量过程中闭式解的方法并不用梯度直接去更新分类器权重，因此对于旧类别区分边界遗忘较少。

在 BloodMNIST 中闭式解持续学习方法有较大优势。说明如果最初的几个任务训练得到编码器提取出的特征具有较好的泛化能力，则之后的任务只需更新解析分类头就可以达到很好的性能。换句话说，在医学图像中一些任务的类别不断增多，但是它们的基本纹理、形状等却是一致的。

从效果上看，闭式解持续学习方法对于这三个数据集都把遗忘率控制在一个很低水平，说明它的统计量递推更新能很好地保存之前学到的知识。但是也要注意，在医学数据中常常存在类别不平衡的问题，所以仍然会对少数类造成影响，在此基础上可以进一步使用类别重加权的方法进行改进。

从临床应用的角度来看，在医学图像任务上，解析持续学习也有三个方面的优势：首先是隐私优势，该方法不用存储历史原始样本，只需要保存一个逆自相关矩阵 Ψ_t 和一个解析分类头 $\hat{\Phi}_t$ ，这更符合医疗行业对于数据保护的要求；其次是效率优势，在增量时期只需要进行一次解析更新，而不需要多次反向传播，对于那些需要不断引入新的疾病类型的医疗机构或者研究机构更加友好；最后是可解释的优势，解析分类头的学习是一个有明确数学表达式的矩阵变化过程，可以更好地从理论上理解知识保持以及增量学习之间的联系，在一些高风险的应用场景下是非常重要的。

5.2 时间序列分类实验

5.2.1 数据集与设置

如表 5-3 所示，本节在五个公开时间序列数据集上对 4.2 节框架的性能做检验，分别是 UCI-HAR^[67]、UWave^[68]、DSA^[69]、GRABMyo^[70] 与 WISDM^[71]。这些数据集覆盖

表 5-3 时间序列实验所用数据集汇总。表中给出每个数据集的通道数 (C)、序列长度 (L)、训练与测试划分、类别数量，并附本实验所采取的任务划分数。

数据集	形状 ($C \times L$)	训练集规模	测试集规模	类别数	实验任务数
UCI-HAR ^[67]	9×128	7352	2947	6	3
UWave ^[68]	3×315	896	3582	8	4
DSA ^[69]	45×125	6840	2280	18	6
GRABMyo ^[70]	28×128	36120	12040	16	5
WISDM ^[71]	3×200	18184	6062	18	6

了人体活动识别、手势识别以及肌电识别等多种时序感知场景，可较为全面地映射时间序列持续学习的实际难度。

UCI-HAR 由智能手机惯性传感器采集的日常活动序列组成，共 6 类；UWave 是基于加速度计的手势识别数据，共 8 类；DSA 来自多传感器体育动作识别，共选取 18 类；GRABMyo 则是一个规模较大的表面肌电手势识别数据集，共 16 类；WISDM 是基于手机与可穿戴设备的人体活动识别数据，一共有 18 类。我们在每个数据集上采用类别增量学习设置，将类别随机打乱后按每个任务包含两类的方式划分为若干个任务，并使用不同随机种子进行多次重复实验，以考察方法对类别顺序变化的鲁棒性。按照文献^[12]的设置，对于类别数量较少的 UCI-HAR 和 UWave 数据集，其完整任务流分别包含 3 个和 4 个实验任务；由于任务数量有限，这两类数据集不再额外划分类别独立的验证任务流，而是在训练数据内部划分验证集按照训练集和验证集九比一用于超参数选择和早停。对于 DSA、GRABMyo 和 WISDM 等类别数量较多的数据集，则先划分 3 个任务作为验证流，用于网格搜索和超参数选择，其余任务作为实验流用于最终结果评估。随后，我们使用在验证流上选定的超参数，在实验流上进行正式的持续学习实验。

5.2.2 评价指标与对比方法

评价指标依旧运用第 2 章 2.6 节定义的平均准确率 (ACC, 式 (2-7)) 与平均遗忘率 (Forgetting, 式 (2-8)), 它们分别映射方法的可塑性与稳定性。

对比方法既包括典型的无样本方法 LwF^[37]、MAS^[36] 与 DT²W^[52]，也包括典型的回放方法 GR^[72]、ER^[34]、iCaRL^[26]、DER^[35]、Herding^[73]、ASER^[74]、CLOPS^[75] 与 FastiCaRL^[56]。其中 Herding 取自 Welling^[73] 提出的样本选择算法，本节把它作为一条独立的回放基线（与 iCaRL 共用的 herding 选择策略思路相近但达成独立），其做法是按特征空间距离贪心地挑选出最具代表性的样本作为缓冲区。除此之外，本节还设置了只在当前任务上训练的 Naive 基线以及联合训练上界 Offline，以便更直观地察看各方法的表

现区间。

完成细节方面，本节选用一维卷积网络作为编码器，初始任务设置与各基线方法保持一致；初始任务训练完成之后冻结编码器，只在后续任务里借助解析分类头做更新。随机高维映射的维度 d_E 设为 8000，正则化系数 γ 依托在验证流任务上做网格搜索得到，集成版本则使用 5 个不同随机初始化的隐藏层做集成。

5.2.3 稳定性与可塑性分析




图 5-1 随着任务推进，各方法在五个数据集上的准确率变化情况。Naive 表示不采用任何增量学习策略的基线方法，Offline 表示一次性在完整数据集上训练的方法。

表 5-4 Naive 表示不采用任何增量学习策略的基线方法，Offline 表示一次性在完整数据集上训练的方法。各指标中排名第一和第二的方法分别用红色与蓝色标注。每个指标均报告 5 次运行结果的均值和标准差。表中 $\mathcal{A}_T$ 与 $\mathcal{F}_T$ 分别对应第 2 章评价指标节中式 (2-7) 定义的 ACC 与式 (2-8) 定义的 Forgetting。

方法	UCI-HAR		UWave		DSA		GRABMyo		WISDM	
	$\mathcal{A}_T \uparrow$	$\mathcal{F}_T \downarrow$	$\mathcal{A}_T \uparrow$	$\mathcal{F}_T \downarrow$	$\mathcal{A}_T \uparrow$	$\mathcal{F}_T \downarrow$	$\mathcal{A}_T \uparrow$	$\mathcal{F}_T \downarrow$	$\mathcal{A}_T \uparrow$	$\mathcal{F}_T \downarrow$
Naive	36.44 $\pm$ 10.35	92.25 $\pm$ 13.25	24.85 $\pm$ 0.12	98.15 $\pm$ 1.40	19.81 $\pm$ 4.12	96.23 $\pm$ 4.95	19.46 $\pm$ 0.34	94.17 $\pm$ 3.34	14.60 $\pm$ 2.25	88.47 $\pm$ 10.58
Offline	92.31 $\pm$ 0.82	N.A	96.39 $\pm$ 0.22	N.A	99.53 $\pm$ 0.76	N.A	93.83 $\pm$ 0.87	N.A	88.60 $\pm$ 1.94	N.A
LwF ^[37]	47.40 $\pm$ 14.04	74.04 $\pm$ 22.17	29.09 $\pm$ 5.34	73.47 $\pm$ 25.06	17.01 $\pm$ 4.33	87.93 $\pm$ 15.21	19.42 $\pm$ 0.32	93.25 $\pm$ 6.64	13.83 $\pm$ 3.51	83.53 $\pm$ 17.51
MAS ^[36]	59.53 $\pm$ 15.90	52.47 $\pm$ 27.00	40.74 $\pm$ 9.29	65.01 $\pm$ 15.14	35.75 $\pm$ 6.35	66.17 $\pm$ 14.57	18.15 $\pm$ 1.57	88.34 $\pm$ 7.52	19.25 $\pm$ 6.66	74.65 $\pm$ 12.06
DT ² W ^[52]	80.15 $\pm$ 6.11	16.55 $\pm$ 9.33	55.09 $\pm$ 9.27	40.28 $\pm$ 18.04	19.06 $\pm$ 4.11	96.85 $\pm$ 4.81	20.09 $\pm$ 7.28	22.57 $\pm$ 9.52	15.59 $\pm$ 7.92	37.50 $\pm$ 14.48
GR ^[72]	80.04 $\pm$ 7.69	25.75 $\pm$ 15.74	85.77 $\pm$ 3.76	15.37 $\pm$ 4.38	69.50 $\pm$ 7.26	36.43 $\pm$ 8.64	20.56 $\pm$ 1.37	94.44 $\pm$ 3.13	24.33 $\pm$ 8.12	85.78 $\pm$ 10.00
ER ^[34]	89.53 $\pm$ 2.41	9.53 $\pm$ 6.54	78.89 $\pm$ 4.27	25.87 $\pm$ 5.68	97.24 $\pm$ 1.43	3.25 $\pm$ 1.78	61.16 $\pm$ 3.30	40.87 $\pm$ 3.59	66.88 $\pm$ 7.36	33.80 $\pm$ 7.90
DER ^[35]	90.75 $\pm$ 1.90	8.58 $\pm$ 5.97	77.74 $\pm$ 6.51	27.31 $\pm$ 7.67	98.01 $\pm$ 0.69	2.28 $\pm$ 0.82	63.78 $\pm$ 3.96	37.01 $\pm$ 3.68	67.14 $\pm$ 5.37	33.38 $\pm$ 6.67
Herding ^[73]	89.95 $\pm$ 2.51	9.96 $\pm$ 7.24	85.42 $\pm$ 1.89	16.51 $\pm$ 1.82	97.75 $\pm$ 1.36	2.62 $\pm$ 1.59	60.07 $\pm$ 3.69	42.46 $\pm$ 4.02	69.67 $\pm$ 3.98	30.04 $\pm$ 3.98
ASER ^[74]	89.82 $\pm$ 1.43	10.20 $\pm$ 5.57	77.89 $\pm$ 5.26	27.14 $\pm$ 6.33	95.97 $\pm$ 6.32	4.73 $\pm$ 7.55	57.90 $\pm$ 4.79	45.49 $\pm$ 5.48	51.48 $\pm$ 15.85	53.04 $\pm$ 18.68
CLOPS ^[75]	89.64 $\pm$ 1.50	8.98 $\pm$ 4.82	73.79 $\pm$ 3.39	32.12 $\pm$ 2.95	89.65 $\pm$ 5.51	12.30 $\pm$ 6.64	52.05 $\pm$ 5.11	52.22 $\pm$ 5.54	44.00 $\pm$ 8.11	60.74 $\pm$ 10.12
FastICARL ^[56]	85.43 $\pm$ 3.74	17.51 $\pm$ 8.25	79.01 $\pm$ 0.98	25.60 $\pm$ 2.24	91.39 $\pm$ 6.16	10.28 $\pm$ 7.44	52.84 $\pm$ 3.49	52.46 $\pm$ 4.19	44.87 $\pm$ 3.67	52.79 $\pm$ 6.37
TS-ACL	90.89 $\pm$ 1.77	4.99 $\pm$ 3.12	93.56 $\pm$ 3.36	3.47 $\pm$ 2.13	98.00 $\pm$ 3.82	1.22 $\pm$ 2.44	68.92 $\pm$ 3.53	12.74 $\pm$ 1.40	86.59 $\pm$ 1.42	5.47 $\pm$ 0.51
TS-ACL-E	88.67 $\pm$ 5.00	5.17 $\pm$ 2.82	95.11 $\pm$ 0.50	2.56 $\pm$ 1.10	99.30 $\pm$ 0.88	0.48 $\pm$ 0.94	75.27 $\pm$ 2.65	10.28 $\pm$ 1.32	87.11 $\pm$ 1.23	5.52 $\pm$ 1.01

如图 5-1 所示，各方法在五个数据集上的准确率随任务推进呈现出明显不同的演化趋势；参见表 5-4，该框架在遗忘率上明显优于已有方法。从数据来看，在 UCI-HAR、UWave、DSA、GRABMyo 与 WISDM 五个数据集上，其遗忘率分别为 4.99%、3.47%、1.22%、12.74% 与 5.47%。汇总来看，这些结果都明显低于大多数基线方法，尤其在 DSA 和 WISDM 等类内变化更为复杂的数据集上优势更为突出。

此结果验证了第一章提出的基本观点：梯度更新造成遗忘的原因之一，以及闭式解增量更新能够在一定程度上避免这种矛盾。因为编码器在第一次之后被冻结，在后续增量中不会对之前学到的特征产生影响；另外，解析分类头利用递归统计量进行增量学习从而获得新的信息，因此以往的知识得到较好的保存。

在准确率方面，该框架同样表现亮眼。五个数据集上的平均准确率分别达到 90.89%、93.56%、98.00%、68.92% 与 86.59%。与无样本持续学习基线相比，这些结果有明显的领先；即便和多种回放方法相比，该框架在大多数数据集上也呈现更优表现或接近 Offline 上界。

特别是在 UWave、DSA 与 WISDM 这类类别边界比较复杂的数据集上，该框架不止规避了遗忘，还能持续推升整体精度。这一点表明多尺度特征融合与随机高维映射确实强化了模型对新类别的适应能力，使得冻结编码器的框架不至于因为缺乏可塑性而表现受限。

5.2.4 消融实验

表 5-5 时间序列消融实验结果，展示不同组件的影响。表中数值为 $\mathcal{A}_T \uparrow$ ，各方法的最佳结果以粗体标出。

Datasets	Deep	Deep+RHL	Deep+RHL+Fusion
UCI-HAR	86.18	87.17	90.89
UWave	87.54	89.86	93.56
DSA	91.65	96.44	98.00
GRABMyo	40.85	56.43	68.92
WISDM	48.98	82.32	86.59

如表 5-5 所示，比较了三种不同的嵌入方式：仅使用深层特征、深层特征加上随机隐藏层、深层特征加上随机隐藏层之后再加上多尺度结合，可以看出随着模块越来越多，模型对于这五个数据集的平均准确率也不断提高。

以 GRABMyo 为例，在仅利用深层特征情况下，其平均准确率为 40.85%，引入随

机隐藏层之后提高至 56.43%，然后再加上多尺度组合后进一步提升到 68.92%。这说明：随机高维映射显著改善特征线性可分能力，而多尺度组合弥补了深层特征对于局部时间序列信息建模不足问题。

对于集成版本，在 UWave、DSA、GRABMyo 以及 WISDM 上都有一定的提升，特别是在 GRABMyo 上的提升显著。而这也说明不同的随机映射形成的多种不同的分类面能够更好地捕捉到类内的差异性，进而提高模型的鲁棒性。

5.2.5 效率分析




图 5-2 五个基准数据集上不同方法的运行时间对比。TS-ACL 在所有数据集上均表现出最快的运行速度，体现了其优越的计算效率。

效率层面的差距落在了图 5-2 中。原因也很清楚：增量部分已不再走多轮反向传播的道路，整个更新过程简化为一次矩阵乘法、一次矩阵求逆的操作——对于每一个新的任务仅需一次解析更新即可完成。这使得每个任务所花费的时间大大减少，在所有五个数据集比较中，TS-ACL 都拥有最短的时间，相比于多次 epoch 回放的方法或者蒸馏的方法有较大提升。

这也不仅仅是快的问题，在可穿戴健康监测、工业物联网传感网、自动驾驶时序感知等应用场景下——它们的一个共同点是计算能力和存储都非常有限，但是又必须不断接受新工作方式的情况下，闭式解持续学习可以用很小的成本满足这个边运行、边学习新工作方式，这也是它工程上的一大优势。

5.3 语义分割实验

5.3.1 数据集与设置

二维图像实验取用 Pascal VOC2012 数据集^[76]。该数据集共有 21 个语义类别（含背景类），训练集为 10582 张图像，验证集为 1449 张图像。本节在该数据集上分别对顺序设定、不相交设定与重叠设定下的类增量语义分割性能进行证实。

三维点云实验运用 S3DIS 与 ScanNet 两个室内场景语义分割数据集^[77-78]。S3DIS 包含 6 个区域共 272 个房间，按惯例以 Area 5 作为检验区域；ScanNet 包含 1513 个室内扫描场景，其中 1210 个用于训练，312 个用于证实。为构造点云增量学习的输入，本节用

滑动窗口对房间做切分，并从每个块里随机采样 2048 个点作为网络输入。在类别顺序方面，本节分别选用按原始标注顺序划分的 S^0 与按类别字母顺序划分的 S^1 两种设置。

落地细节方面，二维图像实验的初始阶段使用 DeepLabv3 加 ResNet-101 主干做监督训练；后续增量阶段冻结编码器，在其后接入随机初始化隐藏层与解析分类头。二维实验的高维映射维度 d_E 设为 8192，岭回归正则项系数 γ 设为 1，二维伪标签阈值 τ 设为 0.4。三维点云实验取用 DGCNN 作为点云编码器，初始阶段按常规分割训练，后续增量阶段同样冻结编码器，只更新高维映射与解析分类头。三维实验中高维映射维度 d_E 设为 5000，正则项 γ 设为 1；伪标签阈值借助交叉检验确定，分别在 S3DIS 与 ScanNet 上设为 0.0035 和 0.001。

5.3.2 评价指标与对比方法

评价指标运用语义分割任务的标准平均交并比 (mIoU)。该指标与第 2 章 §2.6 中式 (2-7) 定义的 ACC 形式上一致——把任务级准确率 $a_{t,i}$ 替换成对应任务上的 mIoU 就可。出于更全面地分析稳定性与可塑性，本节同时报告旧类别集合、新类别集合以及全部类别上的 mIoU：旧类别集合映射知识保留能力，新类别集合映射增量适应能力，全部类别结果映射整体的持续学习性能。

对比方法方面，二维图像实验在 Pascal VOC2012 上与多类典型的类增量语义分割方法做系统比较，所选方法涵盖基于知识蒸馏与背景建模的 LwF^[79]、LwF-MC^[26]、ILT^[80]、CIL^[81]、MiB^[82] 与 PLOP^[11]；以及基于特征/原型蒸馏与结构补偿的 SDR^[83]、UCD+PLOP^[84]、REMINDER^[85]、RCIL^[86]、SPPA^[87]、CAF^[88]、AWT+MiB^[89] 与 EWF+MiB^[90]，还包括近期的 GSC^[91]。与此同时，本节把没有任何持续学习策略的 Naive 作为下界、把参数正则化代表 EWC^[29] 作为参考，并把联合训练 Offline 作为理论上界。

三维点云实验在 S3DIS 与 ScanNet 上与只在初始阶段数据上训练的基础训练 (BT)、Naive 基线、参数正则化方法 EWC^[29]，以及代表性的三维类增量分割方法 Yang et al.^[92] 做比较，并同样把联合训练 Offline 作为理论上界。所有对比方法的结果都直接取自其原论文与综述^[93]。

5.3.3 二维图像结果分析

如表 5-6 与表 5-7 所示，本文方法在 VOC2012 重叠 (overlapped) 15-1 和不相交 (disjoint) 设置下均取得了最优 mIoU；在 15-5 配置下，虽说 ILT 在新类别上 mIoU 略高 (47.8 vs. 42.0) ——但本文方法在旧类别 (78.1 vs. 71.3) 以及全部类别 (70.0 vs. 65.7) 上依旧显著领先，映射了稳定性—可塑性之间更好的折中。在顺序设定下，本文方法在 15-1 配置下取得了 70.0% 的总体 mIoU，其中旧类别为 78.1%，新类别为 42.0%。这一结果表明，即使只在初始阶段训练编码器，后续借助闭式解分类头也能在旧知识维系与

表 5-6 Pascal VOC2012 在顺序 (sequential) 设定下的 CSS mIoU (%) 定量比较。对比方法的结果直接取自原论文和^[93]。最佳结果使用粗体表示。

设定	方法	模型	15-1 (6 阶段)			15-5 (2 阶段)		
			0-15	16-20	全部	0-15	16-20	全部
顺序设定	Naive	DeepLabv3+	49.0	17.8	41.6	62.0	38.1	56.3
	LwF ^[79]	DeepLabv3+	33.7	13.7	29.0	68.0	43.0	62.1
	LwF-MC ^[26]	DeepLabv3+	12.1	1.9	9.7	70.6	19.5	58.4
	ILT ^[80]	DeepLabv3+	49.2	30.3	48.3	71.3	47.8	65.7
	CIL ^[81]	DeepLabv3+	52.4	22.3	45.2	63.8	39.8	58.1
	MiB ^[82]	DeepLabv3+	35.7	11.0	29.8	73.0	44.4	66.1
	SDR ^[83]	DeepLabv3+	58.5	10.1	47.0	73.6	46.7	67.2
	SDR+MiB ^[83]	DeepLabv3+	58.1	11.8	47.1	74.6	43.8	67.3
	本文方法	DeepLabv3	78.1	42.0	70.0	78.1	42.0	70.0

新知识吸收之间保留较好平衡。

到了更具挑战的不相交设定，本文方法在 15-1 配置下取得 68.77% 的总体 mIoU，明显高于已有的代表性方法；在 10-1 配置下，本文方法达到 57.17% 的总体 mIoU，相较一部分现有方法的领先幅度比较显著。这表明伪标签机制能够有效缓解旧类别被错误地吸收进背景的问题。

重叠设定与不相交设定的最大不同点在于背景标签上，在重叠协议中，背景像素既可以是真实的背景也可以是被遮挡的老类别甚至是未来才会出现的新类别，这对伪标签方法提出了更高的要求，在 15-1 以及 10-1 这两种增量协议下我们得到了整体 mIoU 分别为 69.36% 以及 58.91%，由相邻两个阶段图可以看出，性能下降主要集中在第 2~5 个增量之间，在之后基本保持稳定（后续消融实验会有更详细的拆分），也就是说即使加大了对背景语义的不确定性，闭式解更新结合伪标签优化也能够带来一定的收益，这也是本文的方法在重叠协议中的优势所在。

从结果趋势来看，本文的方法对于旧类别的保持效果良好。由于增量阶段不对编码器进行梯度更新，因此旧类别的特征表示是固定的；同时，随机高维映射也使得新的类别更加容易被解析分类头分割开，所以该模型对于旧类别的保持以及新类别的学习效果

表 5-7 Pascal VOC2012 在不相交 (disjoint) 和重叠 (overlapped) 设定下的 CSS mIoU (%) 定量比较。对比方法的结果直接取自原论文和^[93]。最佳结果使用粗体表示。

设定	方法	模型	15-1 (6 阶段)			10-1 (11 阶段)		
			0-15	16-20	全部	0-10	11-20	全部
不相交设定	Naive	DeepLabv3	0.20	1.80	0.60	6.30	1.10	3.80
	MiB ^[82]	DeepLabv3	46.20	12.90	37.90	9.50	4.10	6.90
	PLOP ^[11]	DeepLabv3	57.86	13.67	46.48	9.70	7.00	8.40
	SDR ^[83]	DeepLabv3+	59.40	14.30	48.70	17.30	11.00	14.30
	RCIL ^[86]	DeepLabv3	66.10	18.20	54.70	30.60	4.70	18.20
	本文方法	DeepLabv3	77.66	40.33	68.77	70.85	42.13	57.17
重叠设定	Naive	DeepLabv3	0.20	1.80	0.60	6.30	2.80	4.70
	EWC ^[29]	DeepLabv3	0.30	4.30	1.30	-	-	-
	LwF-MC ^[26]	DeepLabv3	6.40	8.40	6.90	4.65	5.90	4.95
	ILT ^[80]	DeepLabv3	4.90	7.80	5.70	7.15	3.67	5.50
	MiB ^[82]	DeepLabv3	34.22	13.50	29.29	12.25	13.09	12.65
	PLOP ^[11]	DeepLabv3	65.12	21.11	54.64	44.03	15.51	30.45
	UCD+PLOP ^[84]	DeepLabv3	66.30	21.60	55.10	42.30	28.30	35.30
	REMINDER ^[85]	DeepLabv3	68.30	27.23	58.52	-	-	-
	RCIL ^[86]	DeepLabv3	70.60	23.70	59.40	55.40	15.10	34.30
	SPPA ^[87]	DeepLabv3	66.20	23.30	56.00	-	-	-
	CAF ^[88]	DeepLabv3	55.70	14.10	45.30	-	-	-
	AWT+MiB ^[89]	DeepLabv3	59.10	17.20	49.10	33.20	18.00	26.00
	EFW+MiB ^[90]	DeepLabv3	78.00	25.50	65.50	56.00	16.70	37.30
	GSC ^[91]	DeepLabv3	72.10	24.40	60.80	50.60	17.30	34.70
	本文方法	DeepLabv3	79.16	38.00	69.36	75.02	41.20	58.91
Offline	-	DeepLabv3	79.77	72.35	77.43	78.41	76.35	77.43

都非常优秀。

5.3.4 三维点云结果分析

表 5-8 在 S3DIS 和 ScanNet 数据集 S^0 划分下, 三维类增量语义分割方法的定量比较。BT 代表仅在第一步的数据集上训练。增量方法取得的最佳结果以粗体显示。

方法	模型	8-1 (6 阶段)			10-1 (4 阶段)			12-1 (2 阶段)			
		0-7	8-12	全部	0-9	10-12	全部	0-11	12	全部	
S3DIS	BT	DGCNN	49.85	-	-	47.03	-	-	45.37	-	-
	Naive	DGCNN	5.45	4.94	5.25	16.66	11.54	15.48	28.34	34.02	28.77
	EWC ^[29]	DGCNN	30.99	4.16	20.67	39.14	14.73	33.51	37.23	15.49	35.53
	Yang et al. ^[92]	DGCNN	36.90	13.76	27.80	36.98	26.60	34.59	44.54	38.47	44.07
	本文方法	DGCNN	49.77	28.69	41.66	45.26	34.05	42.67	45.19	30.71	44.08
	Offline	DGCNN	48.99	41.76	46.21	46.72	45.11	46.35	47.22	35.65	46.33
方法	模型	15-1 (6 阶段)			17-1 (4 阶段)			19-1 (2 阶段)			
		0-14	15-19	全部	0-16	17-19	全部	0-18	19	全部	
ScanNet	BT	DGCNN	37.52	-	-	34.72	-	-	32.64	-	-
	Naive	DGCNN	4.41	3.20	4.10	2.76	4.19	2.97	11.37	8.86	11.25
	EWC ^[29]	DGCNN	12.32	2.48	9.86	11.34	1.20	9.82	17.84	11.11	17.51
	Yang et al. ^[92]	DGCNN	8.46	4.44	7.46	12.29	6.48	11.42	25.56	11.31	24.85
	本文方法	DGCNN	32.56	10.22	26.97	29.59	12.83	27.98	28.54	16.88	27.96
	Offline	DGCNN	37.59	16.42	32.30	34.78	16.69	32.07	32.28	18.12	32.08

如表 5-8 与表 5-9 所示, 在 S3DIS 数据集上, 本文方法在两种类别顺序设定下都得到了较强的结果。 S^0 划分下, 8-1、10-1 与 12-1 这三种配置的总体 mIoU 分别为 41.66%、42.67% 与 44.08%; S^1 划分下, 对应结果进一步强化到 43.40%、43.04% 与 44.25%。和 Naive 方法以及正则化方法相比, 本文方法在旧类别保留与新类别吸收这两个方面表现得更为均衡。

而在难度更大的 ScanNet 数据集上, 本文方法同样优于现有的增量方法。 S^0 划分

表 5-9 在 S3DIS 和 ScanNet 数据集 S^1 划分下, 三维类增量语义分割方法的定量比较。BT 代表仅在第一步的数据集上训练。增量方法取得的最佳结果以粗体显示。

方法	模型	8-1 (6 阶段)			10-1 (4 阶段)			12-1 (2 阶段)			
		0-7	8-12	全部	0-9	10-12	全部	0-11	12	全部	
S3DIS	BT	DGCNN	37.61	-	-	42.93	-	-	44.68	-	-
	Naive	DGCNN	12.69	2.57	8.80	10.11	2.33	8.31	25.05	11.75	24.04
	EWC ^[29]	DGCNN	17.50	2.59	11.77	20.54	8.86	17.84	23.20	11.40	22.38
	Yang et al. ^[92]	DGCNN	41.28	11.64	29.88	36.45	20.14	31.13	37.38	22.40	36.23
	本文方法	DGCNN	51.33	30.72	43.40	45.16	35.98	43.04	45.65	27.53	44.25
	Offline	DGCNN	39.29	57.42	46.26	42.19	59.08	46.09	46.96	38.89	46.35
方法	模型	15-1 (6 阶段)			17-1 (4 阶段)			19-1 (2 阶段)			
		0-14	15-19	全部	0-16	17-19	全部	0-18	19	全部	
ScanNet	BT	DGCNN	29.01	-	-	30.24	-	-	31.59	-	-
	Naive	DGCNN	4.20	1.61	3.55	3.63	1.00	3.24	9.04	0.22	8.60
	EWC ^[29]	DGCNN	14.93	33.30	19.52	8.78	31.74	12.22	12.65	3.19	12.18
	Yang et al. ^[92]	DGCNN	12.17	0.16	9.17	10.19	5.67	9.52	25.08	15.28	24.59
	本文方法	DGCNN	28.20	16.09	25.18	28.43	15.01	26.42	28.71	11.84	27.84
	Offline	DGCNN	28.93	39.06	31.46	30.12	40.33	31.65	31.29	30.03	31.23

下, 15-1、17-1 与 19-1 这三种配置的总体 mIoU 分别为 26.97%、27.98% 与 27.96%; S^1 划分下, 对应配置的总体 mIoU 则为 25.18%、26.42% 与 27.84%。虽说点云任务本身比二维图像更困难、场景几何结构也更复杂, 但本文方法依旧展现出良好的稳定性和可迁移性。

5.3.5 消融实验

如表 5-10 所示, 旨在进一步分析各模块的作用, 本节在 Pascal VOC2012 的 overlapped 10-1 设置下做了消融实验。完整模型的旧类别、新类别和总体 mIoU 分别为 75.02%、41.20% 与 58.91%。

表 5-10 本文方法代表完整模型设置；w/o RHL 表示模型不包含随机隐藏层（RHL）；w/o Pseudo-Labeling 表示模型不使用伪标签机制。

设置	0 - 10	11 - 20	全部
本文方法	75.02	41.20	58.91
无随机层 (w/o RHL)	63.91	9.36	37.94
无伪标签 (w/o Pseudo-Labeling)	71.83	36.19	54.86

去掉随机初始化隐藏层之后，模型的总体 mIoU 跌至 37.94%，其中新类别 mIoU 仅为 9.36%。这一结果表明：若只冻结编码器并直接接一个线性分类头，模型在学习新类别时缺乏足够的可塑性，高维随机映射对加强线性可分性具有决定性的作用。

去掉伪标签机制之后，模型的总体 mIoU 跌至 54.86%，旧类别和新类别的结果都有明显下滑。这一现象映射：即便选用闭式解更新来规避梯度遗忘，一旦训练标签本身被背景语义污染，模型也会因为监督信号偏移而浮现性能退化。基于此伪标签机制是处置语义漂移问题的必不可少一环。

5.3.6 效率分析

表 5-11 训练时间与 GPU 显存消耗对比，Naive 方法在 Pascal VOC2012 数据集上训练 10 个 epoch。

方法	单轮训练时间	总训练时间	GPU 显存	批量大小
Naive	64.39 s	651.46 s	59.55 GB	32
本文方法 (Ours)	43.25 s	43.25 s	51.61 GB	64

如表 5-11 所示，与 Naive 方法相比，本文方法在增量阶段只需要做一次前向特征提取和一次闭式解更新，故而具备明显的效率优势。实验结果呈现：在 Pascal VOC2012 数据集上，Naive 方法做 10 个 epoch 训练总耗时为 651.46 秒，而本文方法只需要单个 epoch、总耗时 43.25 秒，达成约 15 倍的加速。同时，本文方法还支持更大的批量大小，并且压低了显存占用。

这说明两个方面的问题：其一，闭式解法对持续学习中遗忘有抑制作用；其二，在工程上它也更有效率。从应用角度来说，在需要不断接收新类别的同时又要让模型迅速进行更新的情况下（如边缘视觉设备、在线场景解析或者机器人感知等），这种方法一次性持续学习是有很大实用性的。

5.4 多模态大语言模型专家路由实验

5.4.1 数据集与设置

本节取用多领域多模态持续学习基准 MLLM-CL^[28] 来做实验分析，任务覆盖遥感、医疗、自动驾驶、科学以及金融这五个领域，按领域顺序到达以模拟终身学习数据流。五个领域分别是：遥感（Remote Sensing, RS）、医疗（Medical, Med）、自动驾驶（Autonomous Driving, AD）、科学（Science, Sci）与金融（Finance, Fin），后文表格的列名按此缩写顺序排列。在完成层面，主干分别运用 LLaVA-1.5^[20] 与 InternVL-Chat^[21] 这两种多模态大语言模型，主干参数全程保留冻结；每个领域任务对应一个 LoRA 专家来生成响应，路由头则借助第三章的递归岭回归闭式解，在领域顺序到达的过程中做增量更新。

5.4.2 评价指标与对比方法

评价指标选用第 2 章 2.6 节定义的多模态大语言模型持续学习专用指标：末轮全任务平均性能（MFT，式 (2-10)）、末轮新任务平均性能（MFN，式 (2-10)）、平均累积准确率（MAA，式 (2-10)）以及后向迁移（BWT，式 (2-9)）。MFT 和 MFN 分别代表整个过程最后的整体效果以及对于新任务的学习速度；而 MAA 是对每个时期的效果求均值得到的一个长期效果；BWT 是衡量了一个模型学习完所有的任务之后对于之前任务的记忆程度，在这个值越接近 0 的情况下说明这个系统的遗忘程度就越小。

对比方法涵盖多模态大语言模型领域终身学习的代表性工作，包括：基于低秩适配的微调方法 LoRA-FT^[41]、面向正交子空间扩展的 O-LoRA^[42]、基于 LoRA 专家混合的 MoELoRA^[43] 与 CL-MoE^[94]、基于层次提示与门控的 HiDe^[95]，以及近期的 SEFE^[96] 与 DISCO^[97]。每种方法分别给出无回放与使用回放数据（以 * 标注）这两个版本，以映射其对历史样本的依赖程度。除此之外，本节还把 Zero-shot 作为不更新主干的下界参考，把专家完美选择条件下的结果作为理想上界 Oracle，便于直观比较解析路由相对于梯度路由在稳定性上的差距。基线结果引自^[28]。

5.4.3 主要结果分析

如表 5-12、表 5-13、表 5-14 与表 5-15 所示，本文的解析路由方法在两种主干模型上都呈现出有竞争力的综合表现。以 LLaVA-1.5 为例，该方法在 MFT、MFN、MAA、BWT 四项综合指标上都位居榜首，平均累积准确率（MAA）达到 71.29%，明显高于多种已有基线；更关键的是，其后向迁移（BWT）等于 0.00，表明在整个持续学习过程中几乎没有发生遗忘。在 InternVL-Chat 主干上，本文方法的 MFT 为 68.96%，略低于使用回放数据的 LoRA-FT*（69.43%），但在 MFN（68.96%）、MAA（70.74%）以及 BWT（0.00）这三项指标上依旧大幅领先所有对比基线，并保留 0.00 的后向迁移；这一现象指向：解析路由相对梯度路由在稳定性与无遗忘性上具有综合优势——即便单点性能稍

表 5-12 基于 LLaVA-1.5 的 MLLM-CL 基准领域持续学习结果。基线结果引自^[28]。* 表示使用回放数据的原始方法。

方法	任务性能					综合指标			
	RS	Med	AD	Sci	Fin	MFT↑	MFN↑	MAA↑	BWT↑
Zero-shot	32.29	28.28	15.59	35.55	62.56	34.85	-	-	-
Oracle	81.06	65.83	54.17	56.86	91.14	69.81	-	-	-
LoRA-FT ^[41]	69.65	41.59	25.43	40.88	87.45	64.98	53.00	61.13	-14.97
LoRA-FT* ^[41]	76.54	50.27	43.01	43.32	89.85	66.32	60.60	64.72	-7.15
O-LoRA ^[42]	74.64	44.42	30.02	41.47	87.15	65.16	55.54	62.12	-12.03
O-LoRA* ^[42]	76.94	41.17	34.18	39.61	83.22	60.49	55.02	60.73	-6.83
MoELoRA ^[43]	77.54	41.85	27.62	40.13	86.75	64.94	54.78	61.76	-12.70
MoELoRA* ^[43]	77.63	49.54	39.08	41.04	89.21	66.24	59.30	64.81	-8.68
CL-MoE ^[94]	71.34	46.84	26.33	41.17	88.74	66.06	54.88	61.79	-13.96
CL-MoE* ^[94]	76.58	52.31	39.65	45.64	90.21	66.65	60.88	64.95	-7.22
HiDe ^[95]	74.31	48.95	33.21	38.54	81.55	60.77	55.31	60.68	-6.82
HiDe* ^[95]	74.80	42.29	34.03	38.01	79.22	60.83	53.67	61.81	-8.95
SEFE ^[96]	77.26	50.37	37.21	40.87	86.82	65.01	58.51	63.63	-8.13
SEFE* ^[96]	78.43	52.85	46.21	47.76	89.33	66.89	62.92	66.51	-4.97
DISCO ^[97]	76.03	45.20	43.79	42.33	88.95	64.43	59.26	63.35	-6.46
DISCO* ^[97]	77.78	46.25	50.45	49.51	89.71	65.27	62.74	64.92	-3.17
本文方法	81.28	65.61	54.68	56.89	91.14	69.92	69.92	71.29	0.00

有波动，长期累积和遗忘控制能力依旧占优。

这说明两点：第一，专家隔离可以降低任务间参数间的相互影响，而解析路由可以保证正确专家被准确选择；第二，封闭形式求解可以避免训练路由过程中出现的记忆问题，在总体上获得更好的表现。

进一步看，该解析路由方法在路由准确率上几乎达到了满分。不同领域任务在最后

表 5-13 基于 InternVL-Chat-V1.0 的 MLLM-CL 基准领域持续学习结果。基线结果引自^[28]。* 表示使用回放数据的原始方法。

方法	任务性能					综合指标			
	RS	Med	AD	Sci	Fin	MFT↑	MFN↑	MAA↑	BWT↑
Zero-shot	31.16	29.81	14.06	33.93	64.32	34.66	-	-	-
Oracle	81.49	66.42	54.56	54.48	91.24	69.64	-	-	-
LoRA-FT ^[41]	69.93	52.17	33.04	42.67	91.07	69.06	57.78	65.22	-14.11
LoRA-FT* ^[41]	77.06	47.55	42.67	43.31	91.44	69.43	60.41	67.45	-11.28
MoELoRA ^[43]	69.90	52.08	33.17	42.19	90.58	68.83	57.58	65.97	-14.06
MoELoRA* ^[43]	76.74	52.65	38.81	42.15	89.84	67.90	60.04	66.01	-9.83
HiDe ^[95]	75.40	57.66	36.73	41.48	88.59	65.26	59.97	65.94	-6.60
HiDe* ^[95]	53.17	52.61	40.85	47.04	89.17	64.20	56.57	61.06	-9.54
DISCO ^[97]	75.12	50.69	52.41	50.67	90.86	68.85	63.95	68.14	-6.12
DISCO* ^[97]	77.90	47.50	49.13	49.37	90.92	68.55	62.96	67.81	-6.98
本文方法	81.52	64.42	54.62	53.12	91.10	68.96	68.96	70.74	0.00

阶段的路由准确率基本都保留在 0.999 以上，这表明多模态大语言模型的隐藏状态中已经蕴含了足够强的领域判别信息，解析路由头能够把这些信息高效地映射为专家选择结果。

5.4.4 方法优势与讨论

与传统的梯度式路由器相比，本文的解析路由方法主要具备如下几方面优势。

一是无遗忘。由于每个任务专家彼此隔离，路由头又依托解析方式直接由统计量解出，由此新任务并不会凭借梯度更新去破坏旧任务的路由边界。

二是无回放。系统只需要保存第三章定义的逆自相关矩阵 Ψ_t 和当前路由头 $\hat{\phi}_t$ ，或者说保存 $\mathbf{G}$ 和 $\mathbf{Q}$ 即可，不需要保存之前所有图像、文本或多模态数据，因此对于非常注重隐私或者存储受限的应用较为适用。

三是高效率。路由头的更新只涉及矩阵乘法和矩阵求逆，复杂度远远低于对整个路由网络做多轮梯度训练。对于多模态大语言模型这类参数规模极大的系统而言，这种优

表 5-14 LLaVA-1.5-7B 上的 CF-Router 在终身学习最后阶段的性能。结果报告为 120 次任务排列的均值 $\pm$ 标准差。表中 5 个领域专家准确率列的标准差恒为 0.0000，是因为每个 LoRA 专家在其单一领域上独立训练，专家本身性能不随任务到达顺序变化；标准差仅反映路由阶段对不同到达顺序的差异。

领域	路由准确率	专家准确率
RS	1.0000 $\pm$.0000	0.8128 $\pm$.0000
Med	1.0000 $\pm$.0000	0.6561 $\pm$.0000
AD	1.0000 $\pm$.0000	0.5468 $\pm$.0000
Sci	0.9993 $\pm$.0000	0.5689 $\pm$.0000
Fin	1.0000 $\pm$.0000	0.9114 $\pm$.0000
平均	0.9999 $\pm$.0000	0.6992 $\pm$.0000

表 5-15 InternVL-Chat-V1.0 上的 CF-Router 在终身学习最后阶段的性能。结果报告为 120 次任务排列的均值 $\pm$ 标准差。表中 5 个领域专家准确率列的标准差恒为 0.0000，是因为每个 LoRA 专家在其单一领域上独立训练，专家本身性能不随任务到达顺序变化；标准差仅反映路由阶段对不同到达顺序的差异。

领域	路由准确率	专家准确率
RS	1.0000 $\pm$.0000	0.8152 $\pm$.0000
Med	1.0000 $\pm$.0000	0.6442 $\pm$.0000
AD	1.0000 $\pm$.0000	0.5462 $\pm$.0000
Sci	0.9999 $\pm$.0000	0.5312 $\pm$.0000
Fin	1.0000 $\pm$.0000	0.9110 $\pm$.0000
平均	1.0000 $\pm$.0000	0.6896 $\pm$.0000

势就显得尤为突出。

四是顺序无关性。无论写成第三章中的递归形式，还是写成 $\mathbf{G}$ 与 $\mathbf{Q}$ 的统计量累积形式，其核心更新都是基于二阶统计量与互相关统计量的累加。所以在理想数值条件、固定类别索引映射的前提下，任务顺序并不会改变最终的解析解（这一点已由第三章定

理 3.1 有关递归更新与联合训练严格等价的结论直接保障)。这是传统梯度式方法所难以拥有的性质, 也为持续学习系统的稳定部署带来了便利。

5.5 本章小结

本章在统一实验体系下, 对第四章针对四类典型任务给出的闭式解持续学习应用方法做了较为全面的评估。在医学图像疾病分类任务里, 所提方法在 BloodMNIST、PathMNIST 与 OrganAMNIST 这三个数据集上都取得了明显高于多类传统持续学习基线的平均准确率以及更低的遗忘率, 把解析方法在隐私敏感场景中的实际价值落实了下来。在时间序列分类任务上, 所提方法在 UCI-HAR、UWave、DSA、GRABMyo 与 WISDM 五个数据集上同时拿到了高准确率与低遗忘率, 消融实验也确认了多尺度特征融合和随机高维映射的关键作用, 效率分析则呈现该方法在五个数据集上都具备最快的运行速度。在语义分割任务里, 所提方法在 Pascal VOC2012、S3DIS 与 ScanNet 上均大幅优于现有代表性方法, 消融实验印证了随机高维映射与伪标签机制的必要性, 效率分析则呈现非常大的加速。在多模态大语言模型专家路由任务里, 所提方法在 LLaVA-1.5 与 InternVL-Chat 两种基座模型上都接近无遗忘的水平, 并在路由准确率上几乎达到满分。综合上述结果, 第五章实验从多任务、多模态以及多评测维度证明了第三章统一闭式解理论与第四章针对四类典型任务给出的应用方法在准确率、遗忘率与训练效率上的综合优势。

第 6 章 结论与展望

本文以基于闭式解算法的持续学习方法及其实现为主题，探讨闭式解方法对于不同持续学习问题进行统一建模、推导及实验验证工作。为了解决传统的持续学习方法大多采用梯度下降方式导致容易发生灾难性遗忘并且回放机制存在隐私考虑和消耗大量空间资源的问题，本文从解析持续学习的角度出发，提出了用闭式解来代替增量过程中的梯度更新的方法，并将此应用于分类、分割、时间序列以及多模态大语言模型等多种任务中。在第六章第一节总结全文主要工作并回顾第三章统一数学框架与第四章四种类型的任务应用方法之间的联系，在第二节讨论该方法所存在的不足之处，在第三节提出未来的研究方向，在第四节进行总结。

6.1 全文总结

6.1.1 统一数学框架的建立

第三章给出了递归岭回归闭式解所必需的一般框架。即把连续学习中的固定编码器和更新分类头两部分整合成一个带有 ℓ_2 正则化最小二乘问题，同时用逆自相关矩阵 Ψ_t 以及互相关矩阵 $\mathbf{Q}_t$ 表示历史数据的信息，最后利用 Woodbury 矩阵恒等式得到仅需上一步骤的相关统计量以及当前步骤的新样本即可实现精确更新的方法。并且证明了递归更新的结果与对应的联合训练解析解是相同的，也就说回答了增量过程能否无需使用梯度进行更新的问题。

其一，从理论上讲，这一体系将稳定性和可塑性的冲突变为对二阶统计量进行代数上的管理和维护的问题，在相同理论上可以应用于不同的任务；其二，从算法角度看，每一阶段的学习难度从多轮反向传播降低到一次前向传播，避免了由于梯度下降导致的小范围最优值、超参数调整困难以及难以收敛等缺点；其三，只用存储大小为 $d \times d$ 的数据统计量矩阵而不与历史样本数量相关联因此更适合长时间在线学习的情况。

6.1.2 四类典型任务的应用扩展

第四章基于第三章统一数学基础之上，提出了针对四种不同任务类型的闭式解持续学习的应用。对于医学图像疾病分类任务，将闭式解方法与冻结编码器、解析对齐、递归更新这三个步骤结合在一起，适用于隐私性强并且类别不断增加的医疗环境。对于时间序列分类任务，提出一种时序闭式解的方法，在此基础上采用多尺度特征融合、随机高维映射和集成扩展相结合的方式来解决灾难性遗忘和类内变化的问题。对于语义分割任务，提出一个针对二维图像以及三维点云的通用闭式解持续分割方法，利用冻结编码器、随机高维映射以及为这两者单独设计的伪标签，缓解语义漂移的问题。而对于多模

态大语言模型专家路由任务，将闭式解的思想应用到了专家路由中，设计了一个解析式的任务选择头，实现了无需梯度就可以训练出路由器并且不需要存储任何历史多模态样本即可完成高效的专家路由的目的。

6.1.3 统一实验体系下的系统验证

第五章在统一实验框架下对以上方法进行了大量验证，包括医学图像分类、时间序列分类、二维图像及三维点云语义分割以及多模态大语言模型专家路由等四种类型的任务、共计十几个公开的数据集，均获得了比传统的持续学习基线更高的平均准确率以及更低的遗忘率。

相关研究成果已分别发表于 ACM International Conference on Multimedia (ACM MM, CCF-A)、IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP, CCF-B) 以及 International Conference on Learning Representations Workshop (ICLR Workshop)，另有 1 篇与时间序列持续学习相关的工作投稿至 Knowledge-Based Systems (KBS)，当前在审稿阶段；对应论文均已在第四章各节脚注中给出标注。

6.1.4 方法整体优势

把以上几点结合起来看，基于闭式解的持续学习相比目前主流基于梯度下降的持续学习算法有四个方面优点并且与第一章四个主要成果对应。第一，在更新方式上，对应贡献一（提出使用闭式解代替增量阶段梯度更新的思想）：参数更新是通过一个明确表达式的直接给出，新任务对于旧任务的影响仅体现在对 Ψ_t 和 $\hat{\Phi}_t$ 的简单相加之上，从而避免了增量阶段不同任务梯度之间的冲突，从根本上杜绝了灾难性遗忘的可能性，而且递归解析解和联合训练解析解是等价的。第二，在整体框架上，对应贡献二（构建递归岭回归闭式解的整体数学框架）：该方法用一个统一的统计量维护的方式，使得各种各样的持续学习问题都可以在一个统一的理论下进行描述和解决。第三，在任务推广上，对应贡献三（将整个框架推广到四种常见任务并进行评估）：该方法具有较好的普适性，可以很自然地标准类增量分类推广到稠密预测二维图像分割和三维点云分割、时间序列分类以及多模态大语言模型专家路由等，涵盖了这四类差别很大的任务，形成了一种理论和多个应用的研究模式。第四，在实用价值上，对应贡献四（在效率、隐私以及工程可行性上的好处）：一般情况下增量阶段只需要一轮解析更新而不需要多轮梯度迭代。同时由于这种方法不需要任何历史样本回放，只需要少量的二阶统计量就可以保存所有的历史信息，因此不受样本数量影响，也更加符合医疗影像、边缘计算设备等隐私要求高且硬件资源有限的应用场景。

6.2 方法局限性

尽管本文的方法对多个任务都得到很好的实验结果，但是也不能忽视它的不足之处，在表示的学习、解析分类头模型的能力、任务假设存在一些问题。对于这些问题进行分析有利于了解该方法的应用范围并为后续的研究提供思路。

6.2.1 对初始阶段编码器的依赖

本文采用冻结编码器和递归更新解析分类头两步走方案。这个方案能不能成功实现，取决于最初编码器学到表示是否有足够泛化能力。如果最初任务涵盖种类较少、分布偏差大或者是样本数量不够，那么之后仅通过解析分类头是无法补充底层表示缺失部分。也就是说，该方法有效范围在初始表征已经足够丰富情况下，而对于表征匮乏情况，则仍需使用更好预训练或自适应方法来弥补。

6.2.2 解析分类头的表达力上限

在编码器之后，本文采用线性解析分类头并用随机高维映射解决线性不可分问题。优点是闭式求解可行且具有递归迭代性质；缺点是在一定程度上，对于类内具有丰富模态、类间有显著非线性的数据集，该模型存在一定的上限。集成和多尺度特征融合可以提高此上限但是还是有限的。

6.2.3 任务结构假设较强

对于多模态大语言模型专家路由这部分内容，可做出三个假设：任务有明确分界点、专家数量可数、每个任务样本都能确定唯一的专家编号，在终身学习中这三个条件未必都满足——任务通常是按一定顺序不断到来，它们之间有很多重叠之处，而且新的任务也不一定就要有一个新专家来处理它。因此目前的方法过于关注任务身份，如果要使这个系统更加接近现实世界的应用，则还需要进一步完善其路由机制。

6.3 未来研究展望

为了解决上述问题，在此可以从表征基础、解析分类头模型、任务结构等方面对今后的研究工作进行一些设想。

6.3.1 结合大规模预训练与基础模型

未来可以考虑用更大规模预训练模型或者基础模型作为初始编码器，如 DINOv2、SAM、CLIP 和多模态大语言模型等，从而提升底层表示迁移能力。一方面，预训练模型跨域任务上良好零样本性能大大减少对于初始任务覆盖类别的要求；另一方面，采用分阶段微调或持续预训练方法，使编码器在不影响先前学习结果情况下进行一定程度调整，是将静态预训练和解析持续学习两者结合起来有效手段。

6.3.2 解析分类头模型的非线性扩展

在线性可分时，本文已利用随机高维映射对其进行一定的增强；但是当环境变为更为复杂的真实环境后，模型所能学到的最大能力就达到了瓶颈。未来的研究可以朝向更加丰富的非线性解析建模。一种思路是引入随机傅里叶特征对模型进行核化扩展。

6.3.3 面向开放世界的任务结构扩展

为进一步改进目前基于多模态专家路由方法对于任务边界明确、专家可列举的前提条件所存在的问题，未来的研究可以考虑如下几个方面的工作：第一，将硬路由转化为软路由，使得该方法能够适用于任务之间存在语义重叠的情况；第二，在系统中加入OOD（开放类别）检测以及新的专家自动生成的能力，让系统可以在未知领域中也能具有可解释性和可追踪性的表现。

6.4 本章小结

本章对全文工作进行了总结并对其未来的研究方向进行了展望。本文是以第三章统一方法为基础，在此基础上对四种不同的任务进行研究，在第四章中提出相应的算法并进行实验验证，在第五章中利用统一的实验框架进行系统的比较。基本实现了基于闭式解持续学习的研究。本文的研究成果表明闭式解持续学习不仅是一个有效的减少遗忘的新途径同时也是一种有较高的理论性和实践可行性的持续学习的方法。但是本论文所提出的算法也有其不足之处：如对于编码器的依赖性较强、解析模型的能力有限、任务设置过于简单以及数值不稳定等问题。因此后续的研究可以从以下几个方面入手：一是结合大规模预训练基础的模型；二是对解析分类头模型进行非线性扩展；三是开放世界的任务设置等。希望本文的研究工作可以给持续学习领域提供一种新的思路并且也为闭式解的发展指明方向。

致谢

本科四年的路，从开学报到走到现在写完这篇论文，转眼就到了要落笔说谢谢的时刻。

最先要感谢的是赵荣昌老师。课题方向从最初的几条候选里反复讨论，最后落到闭式解持续学习这条线上；这中间经历过几次推翻重来。每次我拿出半成型的想法时，您都愿意花很长时间，一点一点和我捋清楚问题在哪里、应该怎样继续往下走。论文落笔阶段，您在方法叙述、实验摆放、引用规范等方面的细致打磨，也让我真正看到一篇合格的学术论文应当是什么样子。

我也要感谢戚建宇师兄和李锐师兄。多模态那条线上有不少卡住的地方，比如模型训不动、显存不够，很多问题都是向两位师兄一点点问出来的。写第四章前的实验设计，也和两位师兄讨论过许多次。许多看似零散的建议，最后都实实在在地帮助我把工作往前推进了一步。

谢谢中南大学。在这个校园里读完人生的本科四年，专业上的积累、和老师同学相处的时光、一次次课程学习与科研尝试，都发生在这里。四年前刚入学时，我还并不清楚自己会走向怎样的方向；而现在，我即将从这里出发，保研直博至清华大学计算机系，继续在计算机科学与人工智能相关方向上学习和探索。这既是本科阶段努力的一个阶段性结果，也是一段新的旅程的开始。感谢中南大学给予我的培养、平台与机会，让我能够带着这四年的收获，走向下一段更广阔的求学道路。

最后想说的话，留给家人和朋友。论文里写不出来的那些事，比如投稿被拒后的低落，截稿前熬夜调实验时的疲惫，很多时候你们都一直在。你们的理解、支持和陪伴，是我能走到现在最大的底气。本科四年到这里即将画上句号，但这一路上得到的帮助、鼓励和温暖，我会一直记得。

参考文献

- [1] WANG L, ZHANG X, SU H, et al. A Comprehensive Survey of Continual Learning: Theory, Method and Application[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(8): 5362-5383.
- [2] ZHOU D W, WANG Q W, QI Z H, et al. Class-Incremental Learning: A Survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.
- [3] 周大蔚, 汪福运, 叶翰嘉, 等. 基于深度学习的类别增量学习算法综述[J]. 计算机学报, 2023, 46(8): 1577-1605.
- [4] 王仁振, 孟德宇, 徐宗本. 面向大模型时代的持续学习方法论演变[J]. 自动化学报, 2025, 51: 1-25.
- [5] LEO J, KALITA J. Survey of continuous deep learning methods and techniques used for incremental learning[J]. Neurocomputing, 2024, 582: 127545.
- [6] MCCLOSKEY M, COHEN N J. Catastrophic interference in connectionist networks: The sequential learning problem[G]. in: Psychology of learning and motivation: vol. 24. Elsevier, 1989: 109-165.
- [7] GOODFELLOW I J, MIRZA M, XIAO D, et al. An Empirical Investigation of Catastrophic Forgetting in Gradient-Based Neural Networks[J]. arXiv preprint arXiv:1312.6211, 2013.
- [8] YANG J, SHI R, WEI D, et al. MedMNIST v2: A Large-Scale Lightweight Benchmark for 2D and 3D Biomedical Image Classification[J]. Scientific Data, 2023, 10: 41.
- [9] DERAKHSHANI M M, NAJDENKOSKA I, van SONSBEEK T, et al. Lifelonger: A benchmark for continual disease classification[C]. in: International Conference on Medical Image Computing and Computer-Assisted Intervention. 2022: 314-324.
- [10] CERMELLI F, MANCINI M, ROTA BULO S, et al. Modeling the Background for Incremental Learning in Semantic Segmentation[C]. in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2020: 9233-9242.
- [11] DOUILLARD A, CHEN Y, DAPOGNY A, et al. PLOP: Learning Without Forgetting for Continual Semantic Segmentation[C]. in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2021: 4040-4050.
- [12] QIAO S, PHAM Q, CAO Z, et al. Class-Incremental Learning for Time Series: Benchmark and Evaluation[J]. arXiv preprint arXiv:2402.12035, 2024.
- [13] HUO Y, TANG H. When continue learning meets multimodal large language model: A survey[J]. arXiv preprint arXiv:2503.01887, 2025.

- [14] ZHAI Y, TONG S, LI X, et al. Investigating the catastrophic forgetting in multimodal large language models[J]. arXiv preprint arXiv:2309.10313, 2023.
- [15] WU T, LUO L, LI Y F, et al. Continual learning for large language models: A survey[J]. arXiv preprint arXiv:2402.01364, 2024.
- [16] SHI H, XU Z, WANG H, et al. Continual learning of large language models: A comprehensive survey [J]. arXiv preprint arXiv:2404.16789, 2024.
- [17] GUO H, ZHU F, ZHAO H, et al. MCITlib: Multimodal Continual Instruction Tuning Library and Benchmark[J]. arXiv preprint arXiv:2508.07307, 2025.
- [18] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]. in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [19] DOSOVITSKIY A. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [20] LIU H, LI C, WU Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 34892-34916.
- [21] CHEN Z, WU J, WANG W, et al. Internvl: Scaling up vision foundation models and aligning for generic visual-linguistic tasks[C]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 24185-24198.
- [22] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]. in: International conference on machine learning. 2021: 8748-8763.
- [23] CHEN L C, PAPANDREOU G, SCHROFF F, et al. Rethinking Atrous Convolution for Semantic Image Segmentation[J]. arXiv preprint arXiv:1706.05587, 2017.
- [24] WANG Y, SUN Y, LIU Z, et al. Dynamic Graph CNN for Learning on Point Clouds[J]. ACM Transactions on Graphics, 2019, 38(5): 146:1-146:12.
- [25] SUN L, ZHANG M, WANG B, et al. Few-shot class-incremental learning for medical time series classification[J]. IEEE Journal of Biomedical and Health Informatics, 2023, 28(4): 1872-1882.
- [26] REBUFFI S A, KOLESNIKOV A, SPERL G, et al. iCaRL: Incremental Classifier and Representation Learning[C]. in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2001-2010.
- [27] HOU S, PAN X, LOY C C, et al. Learning a unified classifier incrementally via rebalancing[C]. in: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 831-839.
- [28] ZHAO H, ZHU F, GUO H, et al. Mllm-cl: Continual learning for multimodal large language models [J]. arXiv preprint arXiv:2506.05453, 2025.

- [29] KIRKPATRICK J, PASCANU R, RABINOWITZ N, et al. Overcoming Catastrophic Forgetting in Neural Networks[J]. Proceedings of the National Academy of Sciences, 2017, 114(13): 3521-3526.
- [30] ZENKE F, POOLE B, GANGULI S. Continual learning through synaptic intelligence[C]. in: International conference on machine learning. 2017: 3987-3995.
- [31] LOPEZ-PAZ D, RANZATO M. Gradient episodic memory for continual learning[J]. Advances in neural information processing systems, 2017, 30.
- [32] CHAUDHRY A, ROHRBACH M, ELHOSEINY M, et al. Continual learning with tiny episodic memories[C]. in: Workshop on Multi-Task and Lifelong Reinforcement Learning. 2019.
- [33] CASTRO F M, MARÍN-JIMÉNEZ M J, GUIL N, et al. End-to-end incremental learning[C]. in: Proceedings of the European conference on computer vision (ECCV). 2018: 233-248.
- [34] ROLNICK D, AHUJA A, SCHWARZ J, et al. Experience replay for continual learning[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [35] BUZZEGA P, BOSCHINI M, PORRELLO A, et al. Dark experience for general continual learning: a strong, simple baseline[J]. Advances in neural information processing systems, 2020, 33: 15920-15930.
- [36] ALJUNDI R, BABILONI F, ELHOSEINY M, et al. Memory aware synapses: Learning what (not) to forget[C]. in: Proceedings of the European conference on computer vision (ECCV). 2018: 139-154.
- [37] LI Z, HOIEM D. Learning without forgetting[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(12): 2935-2947.
- [38] RUSU A A, RABINOWITZ N C, DESJARDINS G, et al. Progressive neural networks[J]. arXiv preprint arXiv:1606.04671, 2016.
- [39] ALJUNDI R, CHAKRAVARTY P, TUYTELAARS T. Expert gate: Lifelong learning with a network of experts[C]. in: Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 3366-3375.
- [40] WANG Z, ZHANG Z, EBRAHIMI S, et al. DualPrompt: Complementary Prompting for Rehearsal-free Continual Learning[J]. European Conference on Computer Vision, 2022.
- [41] HU E J, SHEN Y, WALLIS P, et al. Lora: Low-rank adaptation of large language models[J]. arXiv preprint arXiv:2106.09685, 2021.
- [42] WANG X, CHEN T, GE Q, et al. Orthogonal subspace learning for language model continual learning [J]. arXiv preprint arXiv:2310.14152, 2023.
- [43] CHEN C, ZHU J, LUO X, et al. CoIN: A Benchmark of Continual Instruction Tuning for Multimodal Large Language Models[J]. Advances in Neural Information Processing Systems, 2024, 37: 57817-57840.

- [44] ZHUANG H, WENG Z, WEI H, et al. ACIL: Analytic Class-Incremental Learning with Absolute Memorization and Privacy Protection[C]. in: Advances in Neural Information Processing Systems: vol. 35. 2022: 11602-11614.
- [45] ZHUANG H, HE R, TONG K, et al. DS-AL: A Dual-Stream Analytic Learning for Exemplar-Free Class-Incremental Learning[C]. in: Proceedings of the AAAI Conference on Artificial Intelligence: vol. 38: 15. 2024: 17237-17244.
- [46] FANG D, ZHU Y, FANG R, et al. AIR: Analytic Imbalance Rectifier for Continual Learning[J]. arXiv preprint arXiv:2408.10349, 2024.
- [47] ZHUANG H, WENG Z, HE R, et al. GKEAL: Gaussian Kernel Embedded Analytic Learning for Few-Shot Class Incremental Task[C/OL]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 7746-7755. DOI: 10.1109/CVPR52729.2023.00748.
- [48] ZHUANG H, CHEN Y, FANG D, et al. GACL: Exemplar-Free Generalized Analytic Continual Learning[C]. in: Advances in Neural Information Processing Systems. Curran Associates, Inc., 2024.
- [49] ZHUANG H, YAN Y, HE R, et al. Class incremental learning with analytic learning for hyperspectral image classification[J/OL]. Journal of the Franklin Institute, 2024, 361(18): 107285. <https://www.sciencedirect.com/science/article/pii/S0016003224007063>. DOI: <https://doi.org/10.1016/j.jfranklin.2024.107285>.
- [50] HE R, ZHUANG H, FANG D, et al. REAL: Representation Enhanced Analytic Learning for Exemplar-free Class-incremental Learning[EB/OL]. 2024. <https://arxiv.org/abs/2403.13522>. arXiv: 2403.13522 [cs.LG].
- [51] ZHUANG H, FANG D, TONG K, et al. Online Analytic Exemplar-Free Continual Learning with Large Models for Imbalanced Autonomous Driving Task[J/OL]. IEEE Transactions on Vehicular Technology, 2024: 1-10. DOI: 10.1109/TVT.2024.3483557.
- [52] QIAO Z, HU M, JIANG X, et al. Class-Incremental Learning on Multivariate Time Series via Shape-Aligned Temporal Distillation[C]. in: ICASSP 2023 - IEEE International Conference on Acoustics, Speech and Signal Processing. 2023: 1-5.
- [53] DE LANGE M, TUYTELAARS T. Continual prototype evolution: Learning online from non-stationary data streams[C]. in: Proceedings of the IEEE/CVF international conference on computer vision. 2021: 8250-8259.
- [54] ALJUNDI R, LIN M, GOUJAUD B, et al. Gradient based sample selection for online continual learning[J]. Advances in neural information processing systems, 2019, 32.
- [55] ISELE D, COSGUN A. Selective experience replay for lifelong learning[C]. in: Proceedings of the AAAI Conference on Artificial Intelligence: vol. 32: 1. 2018.

- [56] KWON Y D, CHAUHAN J, MASCOLO C. FastICARL: Fast incremental classifier and representation learning with efficient budget allocation in audio sensing applications[J]. arXiv preprint arXiv:2106.07268, 2021.
- [57] ZHU F, ZHANG X Y, CHENG Z, et al. PASS++: A Dual Bias Reduction Framework for Non-Exemplar Class-Incremental Learning[J]. arXiv preprint arXiv:2407.14029, 2024.
- [58] ZHU F, ZHANG X Y, WANG C, et al. Prototype augmentation and self-supervision for incremental learning[C]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 5871-5880.
- [59] SNELL J, SWERSKY K, ZEMEL R. Prototypical networks for few-shot learning[J]. Advances in neural information processing systems, 2017, 30.
- [60] SCHWARZ J, CZARNECKI W, LUKETINA J, et al. Progress & compress: A scalable framework for continual learning[C]. in: International conference on machine learning. 2018: 4528-4537.
- [61] CHAUDHRY A, GORDO A, DOKANIA P, et al. Using hindsight to anchor past knowledge in continual learning[C]. in: Proceedings of the AAAI conference on artificial intelligence: vol. 35: 8. 2021: 6993-7001.
- [62] MALLYA A, DAVIS D, LAZEBNIK S. Piggyback: Adapting a single network to multiple tasks by learning to mask weights[C]. in: Proceedings of the European conference on computer vision (ECCV). 2018: 67-82.
- [63] SERRA J, SURIS D, MIRON M, et al. Overcoming catastrophic forgetting with hard attention to the task[C]. in: International Conference on Machine Learning (ICML). 2018: 4548-4557.
- [64] WANG Y, HUANG Z, HONG X. S-prompts learning with pre-trained transformers: An occam' s razor for domain incremental learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 5682-5695.
- [65] SMITH J S, KARLINSKY L, GUTTA V, et al. Coda-prompt: Continual decomposed attention-based prompting for rehearsal-free continual learning[C]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 11909-11919.
- [66] RAZDAIBIEDINA A, MAO Y, HOU R, et al. Progressive prompts: Continual learning for language models[J]. arXiv preprint arXiv:2301.12314, 2023.
- [67] ISMI D P, PANCHOO S, MURINTO M. K-means clustering based filter feature selection on high dimensional data[J]. International Journal of Advances in Intelligent Informatics, 2016, 2(1): 38-45.
- [68] LIU J, ZHONG L, WICKRAMASURIYA J, et al. uWave: Accelerometer-based personalized gesture recognition and its applications[J]. Pervasive and Mobile Computing, 2009, 5(6): 657-675.
- [69] ALTUN K, BARSHAN B, TUNÇEL O. Comparative Study on Classifying Human Activities with Miniature Inertial and Magnetic Sensors[J]. Pattern Recognition, 2010, 43(10): 3605-3620.

- [70] PRADHAN A, HE J, JIANG N. Multi-day dataset of forearm and wrist electromyogram for hand gesture recognition and biometrics[J]. Scientific data, 2022, 9(1): 733.
- [71] WEISS G M. Wisdm smartphone and smartwatch activity and biometrics dataset[J]. UCI Machine Learning Repository: WISDM Smartphone and Smartwatch Activity and Biometrics Dataset Data Set, 2019, 7: 133190-133202.
- [72] SHIN H, LEE J K, KIM J, et al. Continual learning with deep generative replay[J]. Advances in neural information processing systems, 2017, 30.
- [73] WELLING M. Herding dynamical weights to learn[C]. in: Proceedings of the 26th annual international conference on machine learning. 2009: 1121-1128.
- [74] SHIM D, MAI Z, JEONG J, et al. Online class-incremental continual learning with adversarial shapley value[C]. in: Proceedings of the AAAI Conference on Artificial Intelligence: vol. 35: 11. 2021: 9630-9638.
- [75] KIYASSEH D, ZHU T, CLIFTON D. A clinical deep learning framework for continually learning from cardiac signals across diseases, time, modalities, and institutions[J]. Nature Communications, 2021, 12(1): 4221.
- [76] EVERINGHAM M, VAN GOOL L, WILLIAMS C K I, et al. The Pascal Visual Object Classes (VOC) Challenge[J]. International Journal of Computer Vision, 2010, 88(2): 303-338.
- [77] ARMENI I, SENER O, ZAMIR A, et al. 3D Semantic Parsing of Large-Scale Indoor Spaces[C]. in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 1534-1543.
- [78] DAI A, CHANG A X, SAVVA M, et al. ScanNet: Richly-Annotated 3D Reconstructions of Indoor Scenes[C]. in: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2432-2443.
- [79] LI Z, HOIEM D. Learning without Forgetting[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(12): 2935-2947. DOI: 10.1109/TPAMI.2017.2773081.
- [80] MICHIELI U, ZANUTTIGH P. Incremental Learning Techniques for Semantic Segmentation[C/OL]. in: 2019 IEEE/CVF International Conference on Computer Vision Workshop (ICCVW). 2019: 3205-3212. DOI: 10.1109/ICCVW.2019.00400.
- [81] KLINGNER M, BÄR A, DONN P, et al. Class-incremental learning for semantic segmentation re-using neither old data nor old labels[C]. in: 2020 IEEE 23rd international conference on intelligent transportation systems (ITSC). 2020: 1-8.
- [82] CERMELLI F, MANCINI M, BULO S R, et al. Modeling the background for incremental learning in semantic segmentation[C]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 9233-9242.

- [83] MICIELI U, ZANUTTIGH P. Continual semantic segmentation via repulsion-attraction of sparse and disentangled latent representations[C]. in: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1114-1124.
- [84] YANG G, FINI E, XU D, et al. Uncertainty-aware contrastive distillation for incremental semantic segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 45(2): 2567-2581.
- [85] PHAN M H, PHUNG S L, TRAN-THANH L, et al. Class similarity weighted knowledge distillation for continual semantic segmentation[C]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 16866-16875.
- [86] ZHANG C B, XIAO J W, LIU X, et al. Representation compensation networks for continual semantic segmentation[C]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 7053-7064.
- [87] LIN Z, WANG Z, ZHANG Y. Continual semantic segmentation via structure preserving and projected feature alignment[C]. in: European Conference on Computer Vision. 2022: 345-361.
- [88] YANG G, FINI E, XU D, et al. Continual attentive fusion for incremental learning in semantic segmentation[J]. IEEE Transactions on Multimedia, 2022, 25: 3841-3854.
- [89] GOSWAMI D, SCHUSTER R, van de WEIJER J, et al. Attribution-aware weight transfer: A warm-start initialization for class-incremental semantic segmentation[C]. in: Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2023: 3195-3204.
- [90] XIAO J W, ZHANG C B, FENG J, et al. Endpoints weight fusion for class incremental semantic segmentation[C]. in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7204-7213.
- [91] CONG W, CONG Y, DONG J, et al. Gradient-Semantic Compensation for Incremental Semantic Segmentation[J/OL]. IEEE Transactions on Multimedia, 2024, 26: 5561-5574. DOI: 10.1109/TMM.2023.3336243.
- [92] YANG Y, HAYAT M, JIN Z, et al. Geometry and Uncertainty-Aware 3D Point Cloud Class-Incremental Semantic Segmentation[C/OL]. in: 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 21759-21768. DOI: 10.1109/CVPR52729.2023.02084.
- [93] YUAN B, ZHAO D. A Survey on Continual Semantic Segmentation: Theory, Challenge, Method and Application[J/OL]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2024, 46(12): 10891-10910. DOI: 10.1109/TPAMI.2024.3446949.
- [94] HUAI T, ZHOU J, WU X, et al. CL-MoE: Enhancing Multimodal Large Language Model with Dual Momentum Mixture-of-Experts for Continual Visual Question Answering[J]. arXiv preprint arXiv:2503.00413, 2025.

- [95] GUO H, ZENG F, XIANG Z, et al. HiDe-LLaVA: Hierarchical Decoupling for Continual Instruction Tuning of Multimodal Large Language Model[J]. arXiv preprint arXiv:2503.12941, 2025.
- [96] CHEN J, CONG R, ZHAO Y, et al. SEFE: Superficial and Essential Forgetting Eliminator for Multimodal Continual Instruction Tuning[C]. in: Forty-second International Conference on Machine Learning. 2025.
- [97] GUO H, ZENG F, ZHU F, et al. Federated continual instruction tuning[J]. arXiv preprint arXiv:2503.12897, 2025.